

# Métodos Numéricos

**Rui F. Vigelis**

rfvigelis@gmail.com

Universidade Federal do Ceará – UFC

Versão:

2023-05-21 05:01:31

### Objetivos:

- Capacitar o aluno a identificar e enfrentar os problemas de Engenharia que possam ser resolvidos com técnicas de Métodos Numéricos.

### Frequência:

- $\geq 75\%$ , que equivale a um máximo de 16 horas em faltas.

### Avaliação:

- 3 avaliações progressivas distribuídas durante o semestre.

### Critério de aprovação:

- Se  $7 \leq \text{MAPs}$ , o aluno é aprovado por média.
- Se  $4 \leq \text{MAPs} < 7$ , o aluno faz a prova de avaliação final.
- Se  $4 \leq \text{NAF}$  e  $5 \leq \text{MAF} = \frac{\text{MAPs} + \text{NAF}}{2}$ , o aluno é aprovado.
- Caso contrário, o aluno é reprovado.

### Bibliografia:

- Franco, Neide Bertoldi. **Cálculo Numérico**, 1a. ed. São Paulo: Pearson Prentice Hall, 2006.
- Chapra, Steven C. & Canale, Raymond P. **Métodos Numéricos para Engenharia**, 5a. ed. Porto Alegre: AMGH, 2011.

### Conteúdo:

- Análise de arredondamento (AP1)
- Raízes reais de funções reais (AP1)
- Solução de sistemas lineares (AP2)
- Interpolação polinomial (AP3)
- Integração numérica (AP3)
- Solução numérica de equações diferenciais ordinárias (AP3)

### Definição (Sistema de Ponto Flutuante)

Um número real  $x \neq 0$  é chamado de ponto flutuante (normalizado) se pode ser expresso como

$$x = \pm 0, d_1 d_2 \cdots d_t \times \beta^e,$$

em que

- $\beta$  é a **base**,
- $t$  é o número de dígitos na **mantissa**, com  $d_1 \neq 0$  e  $0 \leq d_j \leq \beta - 1$ , para  $j = 1, \dots, t$ , e
- $e$  é o **exponente**, com  $-m \leq e \leq M$ .

Usamos a notação  $F(\beta, t, m, M)$  para o conjunto de todos os pontos flutuantes, fixados  $\beta$ ,  $t$ ,  $m$  e  $M$ , e adicionando algumas exceções como o zero.

# Métodos Numéricos

## Análise de arredondamento em ponto flutuante

- Muitos programas de computação numérica adotam o padrão IEEE (754 2008) para precisão dupla com 64 bits: 1 para o sinal, 11 para o expoente, 52 para a mantissa.
- No padrão IEEE para precisão dupla, pode-se representar números positivos entre  $2,23 \times 10^{-308}$  e  $1,79 \times 10^{308}$ , aproximadamente.
- O padrão IEEE possui uma representação especial para o zero,  $\pm\infty$  (obtido após a divisão por zero), e NaN (Not a Number, que se obtém em certas operações como  $0/0$ ).



# Métodos Numéricos

## Análise de arredondamento em ponto flutuante

- Seja  $x$  um número real dentro dos limites de representação do sistema em ponto flutuante.
- Se  $x$  não pertence ao conjunto  $F(\beta, t, m, M)$ , ele é representado pelo seu arredondamento em ponto flutuante, que consiste em encontrar  $\bar{x} \in F(\beta, t, m, M)$  tal que  $|x - \bar{x}|$  seja o menor possível.
- Seja  $\text{fl}(\cdot)$  a função que associa um número real  $x$  ao seu arredondamento em ponto flutuante.
- O valor  $|x - \bar{x}|$  é chamado **erro absoluto** de arredondamento, e  $|x - \bar{x}|/|x|$  é chamado de **erro relativo** de arredondamento.

# Métodos Numéricos

## Análise de arredondamento em ponto flutuante

- Utilizaremos a seguinte regra para arredondamento em ponto flutuante.
- Se  $x = 0$ , então  $\bar{x} = 0$ .
- Se  $x \neq 0$ , escolhemos  $f_x$  e  $g_x$  tais que

$$|x| = f_x \times \beta^e + g_x \times \beta^{e-t}, \quad \text{em que } \beta^{-1} \leq f_x < 1 \text{ e } 0 \leq g_x < 1.$$

- O valor absoluto do número arredondado é então dado por

$$|\bar{x}| = \begin{cases} f_x \times \beta^e, & \text{se } g_x < \frac{1}{2}, \\ f_x \times \beta^e + \beta^{e-t}, & \text{se } g_x \geq \frac{1}{2}, \end{cases}$$

e com isso  $\bar{x} = (\text{ sinal } x) |\bar{x}|$ .

# Métodos Numéricos

## Análise de arredondamento em ponto flutuante

### Exemplo

Represente no sistema  $F(10, 3, 5, 5)$  os números:

$$\begin{array}{lll} x_1 = 1234,56, & x_2 = -0,00054962, & x_3 = 0,9995, \\ x_4 = 123456,7, & x_5 = 0,0000001. \end{array}$$

$$\text{R.: } \bar{x}_1 = 0,123 \times 10^4, \bar{x}_2 = -0,550 \times 10^{-3}, \bar{x}_3 = 0,100 \times 10^1, \\ |x_4| = 0,1234567 \times 10^6, |x_5| = 0,1 \times 10^{-6}.$$

### Definição (Épsilon da Máquina)

O **épsilon da máquina**, denotado por  $\varepsilon_{mach}$ , é a metade da distância entre 1 e o menor número em ponto flutuante estritamente maior que 1.

- O épsilon da máquina de um sistema  $F(\beta, t, m, M)$  é

$$\varepsilon_{mach} = \frac{1}{2}\beta^{1-t}.$$

- No padrão IEEE para precisão dupla, tem-se

$$\varepsilon_{mach} = 2^{-52} \approx 2,2 \times 10^{-16}.$$

- O épsilon da máquina  $\varepsilon_{mach}$  fornece um limitante superior para o erro relativo do arredondamento em ponto flutuante.

### Proposição

Seja  $x$  qualquer número real dentro dos limites de representação do sistema. Então existe  $\varepsilon$  com  $|\varepsilon| \leq \varepsilon_{mach}$  tal que

$$\text{fl}(x) = x(1 + \varepsilon).$$

- Se  $g_x < \frac{1}{2}$ , então

$$\begin{aligned}|x - \bar{x}| &= |f_x \times \beta^e + g_x \times \beta^{e-t} - f_x \times \beta^e| \\ &= g_x \times \beta^{e-t} < \frac{1}{2} \beta^{e-t}.\end{aligned}$$

- Se  $g_x \geq \frac{1}{2}$ , então

$$\begin{aligned}|x - \bar{x}| &= |f_x \times \beta^e + g_x \times \beta^{e-t} - f_x \times \beta^e - \beta^{e-t}| \\ &= |g_x - 1| \times \beta^{e-t} \leq \frac{1}{2} \beta^{e-t}.\end{aligned}$$

- Em ambos os casos,

$$\frac{|x - \bar{x}|}{|x|} \leq \frac{\frac{1}{2} \beta^{e-t}}{\beta^{-1} \times \beta^e} = \frac{1}{2} \beta^{1-t},$$

visto que  $|x| \geq \beta^{-1} \times \beta^e$ .

# Métodos Numéricos

## Análise de arredondamento em ponto flutuante

- As operações aritméticas básicas  $+$ ,  $-$ ,  $\times$  e  $/$  com números reais, quando realizadas no computador com sistema  $F(\beta, t, m, M)$  serão denotadas por  $\oplus$ ,  $\ominus$ ,  $\otimes$  e  $\oslash$ .
- As operações aritméticas de ponto flutuante são definidas de modo a satisfazer o axioma:

### Axioma das Operações de Ponto Flutuante

Seja  $*$  uma operação aritmética básica, e  $\circledast$  a respectiva operação em ponto flutuante. A operação  $\circledast$  satisfaz

$$x \circledast y = \text{fl}(x * y),$$

para quaisquer  $x, y \in F(\beta, t, m, M)$ .

- As operações de ponto flutuante não são nem associativas e nem distributivas!

### Exemplo

Considere o sistema  $F(10, 3, 5, 5)$ . Sejam  $x = \text{fl}(11,4)$ ,  $y = \text{fl}(3,18)$  e  $z = \text{fl}(5,05)$ . Efetue as operações:

- (a)  $(x \oplus y) \oplus z$  e  $x \oplus (y \oplus z)$ ;
- (b)  $(y \otimes x) \oslash z$  e  $(y \oslash z) \otimes x$ ;
- (c)  $y \otimes (z \oplus x)$  e  $(y \otimes z) \oplus (y \otimes x)$ .

R.: (a)  $0,197 \times 10^2$  e  $0,196 \times 10^2$ ; (b)  $0,719 \times 10^1$  e  $0,718 \times 10^1$ ; (c)  $0,525 \times 10^1$  e  $0,524 \times 10^1$ .



- Em vista do axioma das operações de ponto flutuante, tem-se:

### Proposição

Para quaisquer  $x, y \in F(\beta, t, m, M)$ , existe  $\varepsilon$  com  $|\varepsilon| \leq \varepsilon_{mach}$  tal que

$$x \circledast y = (x * y)(1 + \varepsilon),$$

em que  $*$  denota uma operação aritmética básica, e  $\circledast$  a respectiva operação em ponto flutuante.

# Métodos Numéricos

## Análise de arredondamento em ponto flutuante

- A seguir veremos dois efeitos numéricos que contribuem para que o resultado obtido não tenha crédito: o cancelamento subtrativo, e a propagação de erro.
- Sejam  $x$  e  $y$  dois números reais dentro dos limites de representação do sistema.
- Na soma desses números em ponto flutuante, tem-se:

$$\begin{aligned}\text{fl}(x) \oplus \text{fl}(y) &= [\text{fl}(x) + \text{fl}(y)](1 + \varepsilon_1) \\ &= [x(1 + \varepsilon_2) + y(1 + \varepsilon_3)](1 + \varepsilon_1) \\ &= x + x(\varepsilon_1 + \varepsilon_2 + \varepsilon_1\varepsilon_2) + y + y(\varepsilon_1 + \varepsilon_3 + \varepsilon_1\varepsilon_3)\end{aligned}$$

com  $|\varepsilon_1|, |\varepsilon_2|, |\varepsilon_3| \leq \varepsilon_{mach}$ .

- Deste modo, para o erro absoluto (EA), podemos escrever

$$EA = |\text{fl}(x) \oplus \text{fl}(y) - (x + y)| \leq (|x| + |y|)(2\varepsilon_{mach} + \varepsilon_{mach}^2).$$

- Já para o erro relativo (ER), temos

$$ER = \frac{|\text{fl}(x) \oplus \text{fl}(y) - (x + y)|}{|x + y|} \leq \frac{|x| + |y|}{|x + y|} (2\varepsilon_{mach} + \varepsilon_{mach}^2).$$

- Como consequência, o erro relativo pode ser grande se  $|x + y|$  for pequeno, ou seja, se  $x \approx -y$ .
- Neste caso, tem-se o chamado **cancelamento subtrativo**.

### Exemplo

No sistema  $F(10, 10, 10, 10)$ , calcule

$$x = \sqrt{9876} - \sqrt{9875}.$$

- Além do cancelamento, pode ocorrer a **propagação de erro**, que é observada em uma sequência de operações aritméticas.

### Exemplo

Considerando o sistema  $F(10, 3, 5, 5)$ , calcule o polinômio

$$P(x) = x^3 - 6x^2 + 4x - 0.1,$$

no ponto 5,24, e compare o resultado com o valor exato

$$P(5,24) = -0,007776.$$

# Métodos Numéricos

## Análise de arredondamento em ponto flutuante

- Um algoritmo  $\mathcal{A}$  é uma sequência de operações aritméticas que gera uma saída  $y$  dada uma entrada  $x$ .
- Seja  $\mathcal{P}$  o problema ao qual o algoritmo  $\mathcal{A}$  se propõe a resolver.
- O algoritmo  $\mathcal{A}$  é chamado de **preciso** (em inglês, *accurate*) se o seu erro relativo é pequeno, ou seja, se

$$\frac{|\mathcal{P}(x) - \mathcal{A}(x)|}{|\mathcal{P}(x)|}$$

é da ordem de  $\varepsilon_{mach}$ .

# Métodos Numéricos

## Análise de arredondamento em ponto flutuante

- Dependendo do contexto, um algoritmo preciso pode ser difícil de ser implementado, pois sempre há a presença de erros de arredondamento em ponto flutuante.
- Podemos usar como requisito outra noção que nos permite analisar a influência de erros de arredondamento em um algoritmo.

### Algoritmo Regressivamente Estável

Um algoritmo  $\mathcal{A}$ , usado para resolver um problema  $\mathcal{P}$ , é chamado de **regressivamente estável** (em inglês, *backward stable*) se

$$\mathcal{P}(\tilde{x}) = \mathcal{A}(x),$$

para algum  $\tilde{x}$  com

$$\frac{|\tilde{x} - x|}{|x|}$$

da ordem de  $\varepsilon_{mach}$ .

### Exemplo

Mostre que a operação  $\text{fl}(x) \oplus \text{fl}(y)$ , que é usado para resolver a soma  $x + y$ , é regressivamente estável num sistema de ponto flutuante com épsilon da máquina  $\varepsilon_{mach}$ .



### Definição

Dada uma função  $f: [a, b] \rightarrow \mathbb{R}$ , um número  $\alpha \in [a, b]$  tal que

$$f(\alpha) = 0$$

é chamado de raiz (ou zero) de  $f$ . Dizemos também que  $\alpha$  é uma solução da equação  $f(x) = 0$ .

- Nem sempre é possível encontrar uma expressão analítica para a raiz de uma função.
- Neste caso, recorreremos a métodos numéricos para aproximar a raiz da função.

- Para garantir a existência de uma raiz de  $f$  em  $[a, b]$ , podemos fazer uso do seguinte resultado:

### Teorema de Bolzano

Seja  $f: [a, b] \rightarrow \mathbb{R}$  uma função contínua. Se  $f(a)f(b) < 0$ , i.e.,  $f(a)$  e  $f(b)$  tem sinais opostos, então existe pelo menos um  $\alpha \in (a, b)$  tal que  $f(\alpha) = 0$ .

- O Teorema de Bolzano é uma consequência do Teorema do Valor Intermediário, visto em Cálculo I.
- Além de garantir a existência da raiz, o Teorema de Bolzano é a base para o método da bissecção.

# Métodos Numéricos

## Método da bissecção

- Seja  $f$  uma função real contínua definida no intervalo  $[a, b]$  tal que  $f(a)f(b) < 0$ .
- O método da bissecção consiste no seguinte procedimento:
  - Calcule o ponto médio do intervalo:

$$m = \frac{a + b}{2}.$$

- Substitua  $a$  ou  $b$  por  $m$  de modo que o novo intervalo contém uma raiz:  
$$\text{se } f(m)f(b) < 0, \text{ então } a \leftarrow m, \text{ senão } b \leftarrow m.$$
  - Repita os passos anteriores até  $(b - a) \leq 2\delta$ .
- O ponto médio entre  $a$  e  $b$  consiste na estimativa da raiz de  $f$ .

- Na  $n$ -ésima iteração, o intervalo resultante terá comprimento  $\frac{b-a}{2^n}$ , que converge para zero com  $n \rightarrow \infty$ .
- A condição de parada é satisfeita se

$$n \geq \log_2\left(\frac{b-a}{\delta}\right) - 1$$

- Neste caso, o erro absoluto da aproximação satisfaz  $|m - \alpha| \leq \delta$ .

# Métodos Numéricos

## Método da bissecção

- Inicialização:
  - Escolha  $a_0$  e  $b_0$  de modo que  $f(a_0)f(b_0) < 0$ .
- Para  $n \geq 0$ :
  - Faça  $x_n = \frac{a_n + b_n}{2}$ .
  - Pare se  $f(x_n) = 0$  ou  $\frac{b_n - a_n}{2} \leq \delta$ .
  - Se  $f(a_n)f(x_n) < 0$ , escolha  $[a_{n+1}, b_{n+1}] = [a_n, x_n]$ ,  
caso contrário,  $[a_{n+1}, b_{n+1}] = [x_n, b_n]$ .

# Métodos Numéricos

## Método da bissecção

### Exemplo

Use o método da bissecção para encontrar uma estimativa para a raiz da função

$$f(x) = e^x - 2x - 1,$$

no intervalo  $[1, 2]$ , considerando uma tolerância  $(b_n - a_n)/2 < \delta = 5 \times 10^{-2}$ .

### Exemplo

Aplique o método da bissecção para encontrar a raiz da função

$$f(x) = \sin(2x) - \cos(3x),$$

no intervalo  $[0, 1]$ , com tolerância  $(b_n - a_n)/2 < \delta = 5 \times 10^{-2}$ .

# Métodos Numéricos


## Método da posição falsa (ou *regula falsi*)

- O método da bissecção, que considera apenas o sinal de  $f$  nos extremos dos intervalos, pode ser modificado para considerarmos os valores de  $f$ .
- No método da posição falsa, em vez de escolhermos o ponto médio do intervalo, adotamos a intersecção do eixo  $x$  com a reta que passa pelos pontos  $(a, f(a))$  e  $(b, f(b))$ .
- Essa intersecção é dada por

$$m = \frac{af(b) - bf(a)}{f(b) - f(a)}.$$

# Métodos Numéricos

Método da posição falsa (ou *regula falsi*)





# Métodos Numéricos

## Método da posição falsa (ou *regula falsi*)

- Inicialização:
  - Escolha  $a_0$  e  $b_0$  de modo que  $f(a_0)f(b_0) < 0$ .
- Para  $n \geq 0$ :
  - Faça  $x_n = b_n - f(b_n) \frac{b_n - a_n}{f(b_n) - f(a_n)}$ .
  - Pare se  $|f(x_n)| < \varepsilon$ .
  - Se  $f(a_n)f(x_n) < 0$ , escolha  $[a_{n+1}, b_{n+1}] = [a_n, x_n]$ ,  
caso contrário,  $[a_{n+1}, b_{n+1}] = [x_n, b_n]$ .

# Métodos Numéricos

## Método da posição falsa (ou *regula falsi*)

### Exemplo

Use o método da posição falsa para encontrar uma estimativa para a raiz da função

$$f(x) = e^x - 2x - 1,$$

no intervalo  $[1, 2]$ , considerando uma tolerância  $|f(x_n)| < \varepsilon = 5 \times 10^{-2}$ .

### Exemplo

Usando o método da posição falsa, encontre a raiz da função

$$f(x) = \sin(2x) - \ln(x),$$

no intervalo  $[1, 3]$ , com tolerância  $|f(x_n)| < \varepsilon = 10^{-4}$ .

# Métodos Numéricos

## Método da iteração de ponto fixo

- Seja  $f$  é uma função contínua em  $[a, b]$ .
- No lugar da equação  $f(x) = 0$ , consideramos o problema na forma

$$x = g(x),$$

em que  $g$  é tal que  $f(\alpha) = 0$  se e somente se  $\alpha = g(\alpha)$ .

- Uma função  $g$  como acima é chamada de função de iteração, e um número  $\alpha$  satisfazendo  $\alpha = g(\alpha)$  é chamado ponto fixo de  $g$ .
- Dada uma aproximação inicial  $x_0$ , o método da iteração de ponto fixo define as aproximações sucessivas

$$x_{n+1} = g(x_n), \quad \text{para } n \geq 0.$$

- Espera-se que  $x_n \rightarrow \alpha$  com  $n \rightarrow \infty$ .

# Métodos Numéricos

## Método da iteração de ponto fixo

### Exemplo

Considere a função  $f(x) = e^x - 2x - 1$ . Mostre que  $g_1(x) = (e^x - 1)/2$  e  $g_2(x) = \ln(2x + 1)$  são funções de iteração para  $f(x)$ .

### Teorema (\*)

Seja  $g: [a, b] \rightarrow \mathbb{R}$  uma função de iteração contínua, com ponto fixo  $\alpha \in (a, b)$ . Assuma que  $g$  é derivável em  $(a, b)$ , e a derivada  $g'(x)$  satisfaz  $|g'(x)| \leq M < 1$ , para todo  $x \in (a, b)$ . Seja  $x_0 \in [a, b]$  qualquer. Então a iteração de ponto fixo

$$x_{n+1} = g(x_n), \quad n \geq 0,$$

está bem definida ( $x_n \in [a, b]$  para todo  $n \geq 1$ ), e converge para  $\alpha$ .

- Pelo Teorema do Valor Médio, existe  $\eta$  entre  $x_{n-1}$  e  $\alpha$  tal que

$$g(x_{n-1}) - g(\alpha) = g'(\eta)(x_{n-1} - \alpha).$$

- Deste modo, podemos escrever

$$|x_n - \alpha| = |g(x_{n-1}) - g(\alpha)| = |g'(\eta)||x_{n-1} - \alpha| \leq M|x_{n-1} - \alpha|.$$

- Com isso, obtemos


$$|x_n - \alpha| \leq M^n |x_0 - \alpha|, \quad \text{para todo } n \geq 0.$$

- Como  $M < 1$ , concluimos que  $x_n \in [a, b]$  para todo  $n \geq 1$ , e

$$\lim_{n \rightarrow \infty} |x_n - \alpha| \leq \lim_{n \rightarrow \infty} M^n |x_0 - \alpha| = 0.$$

# Métodos Numéricos

## Método da iteração de ponto fixo



# Métodos Numéricos

## Método da iteração de ponto fixo

- Inicialização:
  - Escolha  $x_0$ .
- Para  $n \geq 0$ :
  - Faça  $x_{n+1} = g(x_n)$ .
  - Pare se  $|f(x_{n+1})| < \varepsilon$ .



# Métodos Numéricos

## Método da iteração de ponto fixo

### Exemplo

Considere a função  $f(x) = e^x - 2x - 1$ . Usando a aproximação inicial  $x_0 = 1$ , determine as aproximações  $\{x_n\}$  considerando as funções de iteração:

(a)  $g_1(x) = (e^x - 1)/2;$

(b)  $g_2(x) = \ln(2x + 1).$

### Exemplo

Aplique o método da iteração de ponto fixo para encontrar a raiz da função  $f(x) = x^3 - x^2 - 3$  no intervalo  $[1, 3]$ , com função de iteração  $g(x) = (x^2 + 3)^{1/3}$ , ponto inicial  $x_0 = 2,5$ , e tolerância  $|f(x_{n+1})| < \varepsilon = 10^{-1}$ . Verifique as hipóteses que garantem a convergência do método.

### Definição

Seja  $\{x_n\}$  uma sequência convergindo para  $\alpha$ , e seja  $e_n = x_n - \alpha$  seu erro. Considere a condição

$$\lim_{n \rightarrow \infty} \frac{|e_{n+1}|}{|e_n|^p} = \mu,$$

para números reais  $p \geq 1$  e  $\mu \geq 0$ .

- Para  $p = 1$ ,
  - se  $\mu = 0$ , a convergência é **superlinear**,
  - se  $0 < \mu < 1$ , a convergência é **linear** com **taxa de convergência**  $\mu$ ,
  - se  $\mu = 1$ , a convergência é **sublinear**.
- Para  $p > 1$  e  $\mu > 0$ , a convergência é dita ser de **ordem**  $p$ . Em particular, se  $p = 2$ , a convergência é **quadrática**, e se  $p = 3$ , a convergência é **cúbica**.

# Métodos Numéricos

## Método da iteração de ponto fixo

### Definição

A **ordem de convergência** e a **taxa de convergência** de um método numérico são definidas como a ordem de convergência e a taxa de convergência da sequência  $\{x_n\}$  resultante da aplicação do método numérico.

### Teorema

*Suponha que as condições do Teorema (\*) são satisfeitas. Assuma também que  $g'$  é contínua em  $[a, b]$ , e  $x_n \neq \alpha$  para todo  $n \geq 0$ . Seja  $e_n = x_n - \alpha$ . Se  $g'(\alpha) \neq 0$ , então*

$$\lim_{n \rightarrow \infty} \frac{|e_{n+1}|}{|e_n|} = |g'(\alpha)|.$$

- Pelo Teorema do Valor Médio, existe  $\xi_n$  entre  $x_n$  e  $\alpha$  tal que

$$g(x_n) - g(\alpha) = g'(\xi_n)(x_n - \alpha), \quad \text{para } n \geq 0.$$

- Portanto,  $\lim_{n \rightarrow \infty} \xi_n = \alpha$ , e, por  $g'$  ser contínua,

$$\lim_{n \rightarrow \infty} g'(\xi_n) = g'(\alpha).$$

- Deste modo, temos

$$\begin{aligned} \lim_{n \rightarrow \infty} \frac{|e_{n+1}|}{|e_n|} &= \lim_{n \rightarrow \infty} \frac{|x_{n+1} - \alpha|}{|x_n - \alpha|} = \lim_{n \rightarrow \infty} \frac{|g(x_n) - g(\alpha)|}{|x_n - \alpha|} \\ &= \lim_{n \rightarrow \infty} \frac{|g'(\xi_n)(x_n - \alpha)|}{|x_n - \alpha|} \\ &= \lim_{n \rightarrow \infty} |g'(\xi_n)| = |g'(\alpha)|. \end{aligned}$$

### Teorema

Suponha que as condições do Teorema (\*) são satisfeitas. Assuma também que  $g''$  é contínua em  $[a, b]$ , e  $x_n \neq \alpha$  para todo  $n \geq 0$ . Seja  $e_n = x_n - \alpha$ . Se  $g'(\alpha) = 0$  e  $g''(\alpha) \neq 0$ , então

$$\lim_{n \rightarrow \infty} \frac{|e_{n+1}|}{|e_n|^2} = \frac{1}{2}|g''(\alpha)|.$$

- Pela expansão de Taylor, existe  $\xi_n$  entre  $x_n$  e  $\alpha$  tal que

$$g(x_n) = g(\alpha) + g'(\alpha)(x_n - \alpha) + \frac{1}{2}g''(\xi_n)(x_n - \alpha)^2,$$

que implica

$$g(x_n) - g(\alpha) = \frac{1}{2}g''(\xi_n)(x_n - \alpha)^2.$$

- Deste modo, temos

$$\begin{aligned}\lim_{n \rightarrow \infty} \frac{|e_{n+1}|}{|e_n|^2} &= \lim_{n \rightarrow \infty} \frac{|x_{n+1} - \alpha|}{|x_n - \alpha|^2} = \lim_{n \rightarrow \infty} \frac{|g(x_n) - g(\alpha)|}{|x_n - \alpha|^2} \\ &= \lim_{n \rightarrow \infty} \frac{|\frac{1}{2}g''(\xi_n)(x_n - \alpha)^2|}{|x_n - \alpha|^2} \\ &= \lim_{n \rightarrow \infty} \frac{1}{2}|g''(\xi_n)| = \frac{1}{2}|g''(\alpha)|.\end{aligned}$$

# Métodos Numéricos

## Método de Newton

- Considere a função de iteração

$$g(x) = x + A(x)f(x), \quad \text{com } f'(x) \neq 0,$$

onde a função  $A(x)$  é escolhida de modo que  $A(\alpha) \neq 0$ .

- Se escolhermos  $A(x)$  tal que  $g'(\alpha) = 0$ , teremos que  $|g'(x)| < 1$  para todo  $x$  numa vizinhança de  $\alpha$ , o que garante a convergência do método.
- Derivando  $g(x)$ , obtemos

$$g'(x) = 1 + A'(x)f(x) + A(x)f'(x).$$

- Escolhendo

$$A(x) = -\frac{1}{f'(x)},$$

segue que  $g'(\alpha) = 0$ .

- Assim, a escolha

$$g(x) = x - \frac{f(x)}{f'(x)}$$

define o processo iterativo

$$x_{n+1} = x_n - \frac{f(x_n)}{f'(x_n)},$$

chamado de **método de Newton**.

- O método de Newton sempre converge se  $|x_0 - \alpha|$  for suficientemente pequeno.



### Teorema


*Assuma que  $f''$  é contínua em  $[a, b]$ , com  $f'(\alpha) \neq 0$  e  $f''(\alpha) \neq 0$ . Seja  $\{x_n\}$  a sequência obtida no método de Newton. Suponha que  $x_n \neq \alpha$  para todo  $n \geq 0$ . Seja  $e_n = x_n - \alpha$ . Então*

$$\lim_{n \rightarrow \infty} \frac{|e_{n+1}|}{|e_n|^2} = \frac{1}{2} \left| \frac{f''(\alpha)}{f'(\alpha)} \right|.$$

- Esse resultado é uma consequência de  $g'(\alpha) = 0$  e  $g''(\alpha) = \frac{f''(\alpha)}{f'(\alpha)}$ .

# Métodos Numéricos

## Método de Newton



# Métodos Numéricos

## Método de Newton

- Inicialização:
  - Escolha  $x_0$ .
- Para  $n \geq 0$ :
  - Faça  $x_{n+1} = x_n - \frac{f(x_n)}{f'(x_n)}$ .
  - Pare se  $|f(x_{n+1})| < \varepsilon$ .

# Métodos Numéricos

## Método de Newton

### Exemplo

Use o método de Newton para encontrar uma estimativa para a raiz positiva da função

$$f(x) = e^x - 2x - 1,$$

com aproximação inicial  $x_0 = 1$  e tolerância  $\varepsilon = 10^{-5}$ .

### Exemplo

Use o método de Newton para encontrar a raiz da função

$f(x) = \sin(x) - e^{-x}$  no intervalo  $[0, 1]$ , com ponto inicial  $x_0 = 0,0$  e tolerância  $|f(x_{n+1})| < \varepsilon = 10^{-5}$ .

- Uma modificação do método de Newton consiste em substituir a derivada  $f'(x_n)$  pelo quociente


$$f'(x_n) \simeq \frac{f(x_n) - f(x_{n-1})}{x_n - x_{n-1}}.$$

- O método de Newton, com essa modificação, é conhecido como **método das secantes**.
- Com a substituição, obtemos a iteração

$$x_{n+1} = x_n - \frac{f(x_n)(x_n - x_{n-1})}{f(x_n) - f(x_{n-1})}.$$

# Métodos Numéricos

## Método das secantes



# Métodos Numéricos

## Método das secantes

- Inicialização:
  - Escolha  $x_0$  e  $x_1$ .
- Para  $n \geq 1$ :
  - Faça  $x_{n+1} = x_n - \frac{f(x_n)(x_n - x_{n-1})}{f(x_n) - f(x_{n-1})}$ .
  - Pare se  $|f(x_{n+1})| < \varepsilon$ .

### Teorema

*Assuma que  $f'$  é contínua num intervalo  $I$  contendo a raiz  $\alpha$  de  $f$  satisfazendo  $f'(\alpha) \neq 0$ . Seja  $\{x_n\}$  a sequência obtida no método das secantes, com  $x_0$  e  $x_1$  suficientemente próximos a  $\alpha$ . Suponha que  $x_n \neq \alpha$  para todo  $n \geq 0$ . Seja  $e_n = x_n - \alpha$ . Então*

$$\lim_{n \rightarrow \infty} \frac{|e_{n+1}|}{|e_n|^p} = c,$$

*em que  $c > 0$  e  $p = (1 + \sqrt{5})/2 \simeq 1,618$ .*



# Métodos Numéricos

## Método das secantes

### Exemplo

Use o método das secantes para encontrar uma estimativa para a raiz positiva da função

$$f(x) = e^x - 2x - 1,$$

com aproximações iniciais  $x_0 = 1$  e  $x_1 = 2$  e tolerância  $\varepsilon = 10^{-3}$ .

### Exemplo

Aplique o método das secantes para encontrar a raiz da função  $f(x) = \cos(x) - e^{-x}$  no intervalo  $[1, 2]$ , com pontos iniciais  $x_0 = 1,0$  e  $x_1 = 1,2$ , e tolerância  $|f(x_{n+1})| < \varepsilon = 10^{-3}$ .

Um sistema de  $n$  equações lineares é escrito como:

$$\begin{cases} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n = b_1 \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n = b_2 \\ \vdots \\ a_{n1}x_1 + a_{n2}x_2 + \cdots + a_{nn}x_n = b_n \end{cases}$$

em que  $a_{ij}$  são os coeficientes,  $b_i$  são os termos independentes, e  $x_i$  são as incógnitas.

Uma forma conveniente de representar um sistema de  $n$  equações lineares é em sua forma matricial:

$$\begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} = \begin{pmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{pmatrix}$$

ou, simplesmente,

$$Ax = b$$

em que  $A$  é chamada de matriz dos coeficientes,  $b$  é o vetor do termo independente, e  $x$  é o vetor solução.

Métodos numéricos para solução de sistemas de equações lineares podem ser classificados como:

- Métodos Exatos: Executados com um número finito de operações, fornecem a solução exata. Porém, devido a erros de arredondamento, problemas com propagação de erros podem acontecer.
- Métodos Iterativos: A solução é obtida com uma dada precisão, como resultado de um processo iterativo convergente.

### Definição

Seja  $C = (c_{ij})$  uma matriz quadrada. A matriz  $C$  é chamada de triangular superior (triangular inferior) se  $c_{ij} = 0$  para  $i > j$  ( $i < j$ ).

### Definição

Um sistema de equações lineares é chamado de triangular superior (triangular inferior) se a matriz dos coeficientes for triangular superior (triangular inferior).

# Métodos Numéricos

## Solução de sistemas triangulares

Assumindo  $a_{ii} \neq 0$ , o sistema triangular superior

$$\begin{pmatrix} a_{11} & a_{12} & a_{13} & \cdots & a_{1n} \\ 0 & a_{22} & a_{23} & \cdots & a_{2n} \\ 0 & 0 & a_{33} & \cdots & a_{3n} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \cdots & a_{nn} \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ \vdots \\ x_n \end{pmatrix} = \begin{pmatrix} b_1 \\ b_2 \\ b_3 \\ \vdots \\ b_n \end{pmatrix}$$

pode ser resolvido usando a seguinte fórmula, chamada de substituição reversa:

$$\begin{cases} x_n = \frac{b_n}{a_{nn}} \\ x_i = \frac{b_i - \sum_{j=i+1}^n a_{ij}x_j}{a_{ii}}, & i = n-1, \dots, 1 \end{cases}$$

# Métodos Numéricos

## Solução de sistemas triangulares

Já o sistema triangular inferior, com  $a_{ii} \neq 0$ ,

$$\begin{pmatrix} a_{11} & 0 & 0 & \cdots & 0 \\ a_{21} & a_{22} & 0 & \cdots & 0 \\ a_{31} & a_{32} & a_{33} & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & a_{n3} & \cdots & a_{nn} \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ \vdots \\ x_n \end{pmatrix} = \begin{pmatrix} b_1 \\ b_2 \\ b_3 \\ \vdots \\ b_n \end{pmatrix}$$

pode ser resolvido usando a seguinte fórmula, chamada de substituição direta:

$$\begin{cases} x_1 = \frac{b_1}{a_{11}} \\ x_i = \frac{b_i - \sum_{j=1}^{i-1} a_{ij}x_j}{a_{ii}}, & i = 2, \dots, n \end{cases}$$

### Exemplo

Resolva o sistema triangular superior

$$\begin{pmatrix} 2 & 3 & 4 \\ 0 & -1 & -2 \\ 0 & 0 & -3 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 0 \\ -2 \\ -3 \end{pmatrix}.$$

R.:  $(-2, 0, 1)^T$ .

### Exemplo

Resolva o sistema triangular superior

$$\begin{pmatrix} 4 & -1 & 3 & 4 \\ 0 & 2 & -3 & 5 \\ 0 & 0 & 7 & -3 \\ 0 & 0 & 0 & 2 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{pmatrix} = \begin{pmatrix} 12 \\ 7 \\ -13 \\ 4 \end{pmatrix}.$$

R.:  $(1, -3, -1, 2)^T$ .



### Exemplo

Resolva o sistema triangular inferior

$$\begin{pmatrix} -7 & 0 & 0 \\ 3 & 1 & 0 \\ 9 & -5 & 2 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} -21 \\ 7 \\ 39 \end{pmatrix}.$$

R.:  $(3, -2, 1)^T$ .

### Exemplo

Resolva o sistema triangular inferior

$$\begin{pmatrix} 3 & 0 & 0 & 0 \\ 4 & 2 & 0 & 0 \\ -1 & 3 & 3 & 0 \\ 2 & -1 & -2 & -5 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{pmatrix} = \begin{pmatrix} -3 \\ 0 \\ 16 \\ -5 \end{pmatrix}.$$

R.:  $(-1, 2, 3, -1)^T$ .

# Métodos Numéricos

## Método da eliminação de Gauss

Considere a matriz aumentada

$$\tilde{A}^{(1)} = (A^{(1)}, b^{(1)}) = \begin{pmatrix} a_{11}^{(1)} & a_{12}^{(1)} & a_{13}^{(1)} & \cdots & a_{1n}^{(1)} & b_1^{(1)} \\ a_{21}^{(1)} & a_{22}^{(1)} & a_{23}^{(1)} & \cdots & a_{2n}^{(1)} & b_2^{(1)} \\ a_{31}^{(1)} & a_{32}^{(1)} & a_{33}^{(1)} & \cdots & a_{3n}^{(1)} & b_3^{(1)} \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ a_{n1}^{(1)} & a_{n2}^{(1)} & a_{n3}^{(1)} & \cdots & a_{nn}^{(1)} & b_n^{(1)} \end{pmatrix},$$

em que  $a_{ij}^{(1)} = a_{ij}$  e  $b_i^{(1)} = b_i$ .

Em cada estágio do método da eliminação de Gauss, os elementos da  $k$ -ésima coluna abaixo da diagonal são zerados.

# Métodos Numéricos

## Método da eliminação de Gauss

Na primeiro estágio, obtemos

$$\tilde{A}^{(2)} = (A^{(2)}, b^{(2)}) = \begin{pmatrix} a_{11}^{(2)} & a_{12}^{(2)} & a_{13}^{(2)} & \cdots & a_{1n}^{(2)} & b_1^{(2)} \\ & a_{22}^{(2)} & a_{23}^{(2)} & \cdots & a_{2n}^{(2)} & b_2^{(2)} \\ & a_{32}^{(2)} & a_{33}^{(2)} & \cdots & a_{3n}^{(2)} & b_3^{(2)} \\ & \vdots & \vdots & \ddots & \vdots & \vdots \\ & a_{n2}^{(2)} & a_{n3}^{(2)} & \cdots & a_{nn}^{(2)} & b_n^{(2)} \end{pmatrix},$$

Já no segundo,

$$\tilde{A}^{(3)} = (A^{(3)}, b^{(3)}) = \begin{pmatrix} a_{11}^{(3)} & a_{12}^{(3)} & a_{13}^{(3)} & \cdots & a_{1n}^{(3)} & b_1^{(3)} \\ & a_{22}^{(3)} & a_{23}^{(3)} & \cdots & a_{2n}^{(3)} & b_2^{(3)} \\ & & a_{33}^{(3)} & \cdots & a_{3n}^{(3)} & b_3^{(3)} \\ & & \vdots & \ddots & \vdots & \vdots \\ & & a_{n3}^{(3)} & \cdots & a_{nn}^{(3)} & b_n^{(3)} \end{pmatrix}$$

Continuamos até chegarmos à matriz triangular superior

$$\tilde{A}^{(n)} = (A^{(n)}, b^{(n)}) = \begin{pmatrix} a_{11}^{(n)} & a_{12}^{(n)} & a_{13}^{(n)} & \cdots & a_{1n}^{(n)} & b_1^{(n)} \\ & a_{22}^{(n)} & a_{23}^{(n)} & \cdots & a_{2n}^{(n)} & b_2^{(n)} \\ & & a_{33}^{(n)} & \cdots & a_{3n}^{(n)} & b_3^{(n)} \\ & & & \ddots & \vdots & \vdots \\ & & & & a_{nn}^{(n)} & b_n^{(n)} \end{pmatrix}$$

Podemos então encontrar a solução de  $Ax = b$  como solução do sistema triangular superior  $A^{(n)}x = b^{(n)}$ .

# Métodos Numéricos

## Método da eliminação de Gauss

- Para zerar os elementos da  $k$ -ésima coluna abaixo da diagonal, substituímos a  $i$ -ésima linha pela diferença entre a  $i$ -ésima linha e a  $k$ -ésima linha multiplicada por  $m_{ik} = \frac{a_{ik}^{(k)}}{a_{kk}^{(k)}}$ .
- Equivalentemente, para  $k = 1, \dots, n - 1$ ,

$$\begin{cases} m_{ik} = \frac{a_{ik}^{(k)}}{a_{kk}^{(k)}} \\ a_{ij}^{(k+1)} = a_{ij}^{(k)} - m_{ik} a_{kj}^{(k)} \\ b_i^{(k+1)} = b_i^{(k)} - m_{ik} b_k^{(k)} \end{cases}$$

para  $i = k + 1, \dots, n$  e  $j = k, \dots, n$ .

- O termo  $a_{kk}^{(k)}$  é chamado de pivô.

### Resultado

Para garantirmos que  $a_{kk}^{(k)} \neq 0$ , para  $k = 1, \dots, n$ , devemos assumir que  $\det(A_k) \neq 0$ , em que  $A_k = (a_{ij})_{k \times k}$  é o menor principal de  $A$  de ordem  $k$ .

Para calcularmos o número de operações no método da eliminação de Gauss, escrevemos

$$\begin{aligned}\# \text{ operações} &= \sum_{k=1}^{n-1} (\# \text{ operações no estágio } k) \\ &= \sum_{k=1}^{n-1} \sum_{i=k+1}^n (\# \text{ operações na linha } i)\end{aligned}$$

- Com isso, temos

$$\# \text{ divisões} = \sum_{k=1}^{n-1} \sum_{i=k+1}^n 1 = \frac{(n-1)n}{2}$$

e

$$\begin{aligned} \# \text{ multiplicações} &= \sum_{k=1}^{n-1} \sum_{i=k+1}^n \{[n - (k-1)] + 1\} \\ &= \frac{2n^3 + 3n^2 - 5n}{6} \end{aligned}$$

- O número de subtrações é igual ao número de multiplicações.
- Portanto, o método da eliminação de Gauss possui uma complexidade aritmética da ordem de  $n^3$ .



# Métodos Numéricos

## Método da eliminação de Gauss

### Exemplo

Use o método da eliminação de Gauss para resolver o sistema

$$\begin{pmatrix} 1 & 3 & -2 \\ -1 & 0 & 0 \\ 2 & -3 & 1 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 2 \\ -1 \\ 0 \end{pmatrix}.$$

R.:  $(1, 1, 1)^T$ .

### Exemplo

Use o método da eliminação de Gauss para resolver o sistema

$$\begin{pmatrix} 1 & -3 & 2 \\ 2 & -2 & 3 \\ 3 & -13 & 9 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 12 \\ 15 \\ 47 \end{pmatrix}.$$

R.:  $(4, -2, 1)^T$ .

# Métodos Numéricos

## Método da eliminação de Gauss

### Exemplo

Usando o método da eliminação de Gauss, resolva o sistema

$$\begin{pmatrix} 1 & -1 & 2 & -1 \\ -3 & 5 & -3 & 2 \\ 1 & -5 & -6 & 2 \\ 3 & -11 & -8 & 1 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{pmatrix} = \begin{pmatrix} -8 \\ 21 \\ 3 \\ -8 \end{pmatrix}.$$

R.:  $(-1, 2, -2, 1)^T$ .

### Exemplo

Usando o método da eliminação de Gauss, resolva o sistema

$$\begin{pmatrix} 3 & -2 & 1 & -1 \\ 6 & -6 & 1 & 1 \\ -9 & -2 & -8 & 17 \\ -6 & -2 & -4 & 7 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{pmatrix} = \begin{pmatrix} -15 \\ -30 \\ 48 \\ 25 \end{pmatrix}.$$

R.:  $(-3, 2, -1, 1)^T$ .

### Exemplo

Resolva o sistema

$$\begin{cases} 0,0003x_1 + 3,0000x_2 = 2,0001 \\ 1,0000x_1 + 1,0000x_2 = 1,0000 \end{cases}$$

usando o método da eliminação de Gauss, com quatro e cinco algarismos significativos.

R.:  $(1,0000; 0,6666)^T$ ,  $(0,40000; 0,66666)^T$ ,  $(1/3, 2/3)^T$ .

### Exemplo

Resolva o sistema

$$\begin{cases} 1,0000x_1 + 1,0000x_2 = 1,0000 \\ 0,0003x_1 + 3,0000x_2 = 2,0001 \end{cases}$$

usando o método da eliminação de Gauss, com quatro e cinco algarismos significativos.

R.:  $(0,3334; 0,6666)^T$ ,  $(0,33334; 0,66666)^T$ ,  $(1/3, 2/3)^T$ .

### Pivotamento parcial

No método da eliminação de Gauss com pivotamento parcial, antes de iniciar o  $k$ -ésimo estágio, as linhas da matriz  $A^{(k)}$  são permutadas de modo que  $|a_{kk}^{(k)}| \geq |a_{ik}^{(k)}|$ , para  $i = k, \dots, n$ . O pivô é escolhido como sendo um dos elementos de maior valor absoluto dentre  $a_{kk}^{(k)}, a_{k+1,k}^{(k)}, \dots, a_{nk}^{(k)}$ .

### Exemplo

Resolva o sistema  $Ax = b$ , em que

$$A = \begin{pmatrix} 1 & -2 & -1 \\ 2 & 2 & 1 \\ 3 & 1 & -8 \end{pmatrix}, \quad \text{e} \quad b = \begin{pmatrix} -1 \\ 10 \\ -6 \end{pmatrix},$$

usando o método da eliminação de Gauss com pivotamento parcial.

R.:  $x = (3, 1, 2)^T$ .

### Exemplo

Resolva o sistema abaixo, com precisão de duas casas decimais, usando o método da eliminação de Gauss com pivotamento parcial:

$$\begin{pmatrix} -2 & 1 & 1 \\ 2 & 3 & 3 \\ 3 & 2 & -1 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 1 \\ -3 \\ 2 \end{pmatrix}.$$

(Obs.: O arredondamento deve ser aplicado a cada operação aritmética.)

R.:  $(-0,74; 1,24; -1,74)^T$ .

- Seja  $A$  uma matriz quadrada. A fatoração LU da matriz  $A$  se refere ao produto

$$A = LU,$$

em que  $L$  é uma matriz triangular inferior, com os termos da diagonal iguais a 1, e  $U$  é uma matriz triangular superior.

- Uma aplicação do método da eliminação de Gauss fornece a decomposição LU da matriz  $A$ .



- Organizamos os multiplicadores  $m_{ik} = a_{ik}^{(k)} / a_{kk}^{(k)}$  na matriz triangular inferior

$$L = \begin{pmatrix} 1 & 0 & 0 & \cdots & 0 \\ m_{21} & 1 & 0 & \cdots & 0 \\ m_{31} & m_{32} & 1 & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ m_{n1} & m_{n2} & m_{n3} & \cdots & 1 \end{pmatrix}.$$

- Seja  $U = A^{(n)}$  a matriz triangular superior obtida no final do método da eliminação de Gauss.
- Essas matrizes satisfazem

$$A = LU.$$

- Uma vez encontrada a fatoração LU da matriz  $A$ , o sistema  $Ax = b$  é resolvido da seguinte forma:
  - Primeiro, usando substituição direta, resolve-se  $Ly = b$ .
  - Depois, usando substituição reversa, resolve-se  $Ux = y$ .
- O procedimento acima é útil no caso em que o sistema linear  $Ax = b$  precisa ser resolvido, com a mesma matriz  $A$ , e diferentes vetores  $b$ , pois não é necessário fatorar a matriz  $A$  novamente.

### Exemplo

Encontre a fatoração LU da matriz

$$A = \begin{pmatrix} -1 & 2 & 3 \\ -2 & 7 & 4 \\ 3 & 9 & -15 \end{pmatrix},$$

e posteriormente resolva o sistema  $Ax = b$  para  $b = (5, 18, 21)^T$  e  $b = (5, 9, -12)^T$ .

$$\text{R.: } \begin{pmatrix} 1 & 0 & 0 \\ 2 & 1 & 0 \\ -3 & 5 & 1 \end{pmatrix} \begin{pmatrix} -1 & 2 & 3 \\ 0 & 3 & -2 \\ 0 & 0 & 4 \end{pmatrix}, \begin{pmatrix} -4 \\ 2 \\ -1 \end{pmatrix}, \begin{pmatrix} 3 \\ 1 \\ 2 \end{pmatrix}.$$

### Exemplo

Encontre a fatoração LU da matriz

$$A = \begin{pmatrix} 2 & 3 & -2 & -1 \\ 4 & 4 & -1 & -6 \\ 4 & 14 & -19 & 16 \\ -4 & 2 & -17 & 22 \end{pmatrix},$$

e posteriormente resolva o sistema  $Ax = b$  para  $b = (-3, -11, 21, 43)^T$  e  $b = (-8, -20, 8, 54)^T$ .

$$R.: \begin{pmatrix} 1 & 0 & 0 & 0 \\ 2 & 1 & 0 & 0 \\ 2 & -4 & 1 & 0 \\ -2 & -4 & 3 & 1 \end{pmatrix} \begin{pmatrix} 2 & 3 & -2 & -1 \\ 0 & -2 & 3 & -4 \\ 0 & 0 & -3 & 2 \\ 0 & 0 & 0 & -2 \end{pmatrix}, \begin{pmatrix} 3 \\ -3 \\ -1 \\ 2 \end{pmatrix}, \begin{pmatrix} -1 \\ -3 \\ -2 \\ 1 \end{pmatrix}.$$

# Métodos Numéricos

## Método de Jacobi

Isolando a variável  $x_i$  na  $i$ -ésima linha do sistema

$$\begin{cases} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n = b_1 \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n = b_2 \\ \vdots \\ a_{n1}x_1 + a_{n2}x_2 + \cdots + a_{nn}x_n = b_n \end{cases}$$

podemos escrever

$$\begin{cases} x_1 = (b_1 - a_{12}x_2 - \cdots - a_{1n}x_n)/a_{11} \\ x_2 = (b_2 - a_{21}x_1 - \cdots - a_{2n}x_n)/a_{22} \\ \vdots \\ x_n = (b_n - a_{n1}x_1 - \cdots - a_{n,n-1}x_{n-1})/a_{nn} \end{cases}$$

# Métodos Numéricos

## Método de Jacobi

No método de Jacobi, a sequência de aproximações  $x^{(k)}$  para a solução do sistema  $Ax = b$  é dada pela fórmula recursiva

$$\begin{cases} x_1^{(k+1)} = (b_1 - a_{12}x_2^{(k)} - \cdots - a_{1n}x_n^{(k)})/a_{11} \\ x_2^{(k+1)} = (b_2 - a_{21}x_1^{(k)} - \cdots - a_{2n}x_n^{(k)})/a_{22} \\ \vdots \\ x_n^{(k+1)} = (b_n - a_{n1}x_1^{(k)} - \cdots - a_{n,n-1}x_{n-1}^{(k)})/a_{nn} \end{cases}$$

em que assumimos  $a_{ii} \neq 0$ .

# Métodos Numéricos

## Método de Jacobi

Podemos reescrever a fórmula recursiva para o método de Jacobi na forma matricial

$$x^{(k+1)} = D^{-1}(b - Mx^{(k)}), \quad k \geq 0,$$

em que  $D$  e  $M$  são matrizes satisfazendo  $A = D + M$ , com

$$D = \begin{pmatrix} a_{11} & 0 & \cdots & 0 \\ 0 & a_{22} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & a_{nn} \end{pmatrix}, \quad \text{e} \quad M = \begin{pmatrix} 0 & a_{12} & \cdots & a_{1n} \\ a_{21} & 0 & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & 0 \end{pmatrix}.$$

- Para a parada do método de Jacobi podemos usar o critério

$$\frac{\|x^{(k+1)} - x^{(k)}\|_{\infty}}{\|x^{(k+1)}\|_{\infty}} < \varepsilon,$$

dada uma tolerância  $\varepsilon > 0$ .

- A norma  $\|\cdot\|_{\infty}$  corresponde ao maior dos valores absolutos dos componentes do vetor, i.e., se  $x = (x_1, \dots, x_n)^T$  então

$$\|x\|_{\infty} = \max_{1 \leq i \leq n} |x_i|.$$



# Métodos Numéricos

## Método de Jacobi

### Exemplo

Use o método de Jacobi, com aproximação inicial  $x^{(0)} = (0,0)^T$ , e  $\varepsilon = 5 \times 10^{-2}$  para o critério de parada, para encontrar a solução do sistema linear

$$\begin{cases} 3x_1 - 2x_2 = 1 \\ -x_1 + 4x_2 = 1 \end{cases}$$

R.:

$k$	$x^{(k)}$	$\frac{\ x^{(k)} - x^{(k-1)}\ _{\infty}}{\ x^{(k)}\ _{\infty}}$
0	$(0,00000; 0,00000)^T$	
1	$(0,33333; 0,25000)^T$	1,00000
2	$(0,50000; 0,33333)^T$	0,33333
3	$(0,55555; 0,37500)^T$	0,09999
4	$(0,58333; 0,38888)^T$	0,04762

### Exemplo

Considere o sistema linear

$$\begin{pmatrix} 4 & -2 & 1 \\ 1 & -3 & -1 \\ -1 & 0 & 2 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 2 \\ 4 \\ -1 \end{pmatrix}.$$

Dada a aproximação inicial  $x^{(0)} = (0, 0, 0)^T$ , encontre as aproximações sucessivas  $x^{(1)}$ ,  $x^{(2)}$ ,  $x^{(3)}$  e  $x^{(4)}$ , usando o método de Jacobi.

R.: Solução:  $(0,04; -1,16; -0,48)^T$ . Aproximações:

$k$	$x^{(k)}$
0	$(0,00000; 0,00000; 0,00000)^T$
1	$(0,50000; -1,33333; -0,50000)^T$
2	$(-0,04166; -1,00000; -0,25000)^T$
3	$(0,06250; -1,26388; -0,52083)^T$
4	$(-0,00173; -1,13889; -0,46875)^T$

# Métodos Numéricos

## Método de Gauss–Seidel

No método de Gauss–Seidel, a sequência de aproximações  $x^{(k)}$  para a solução do sistema  $Ax = b$  é dada pela fórmula recursiva (assumimos  $a_{ii} \neq 0$ )

$$\begin{cases} x_1^{(k+1)} = (b_1 - a_{12}x_2^{(k)} - \dots - a_{1n}x_n^{(k)})/a_{11} \\ x_2^{(k+1)} = (b_2 - a_{21}x_1^{(k+1)} - \dots - a_{2n}x_n^{(k)})/a_{22} \\ \vdots \\ x_n^{(k+1)} = (b_n - a_{n1}x_1^{(k+1)} - \dots - a_{n,n-1}x_{n-1}^{(k+1)})/a_{nn} \end{cases}$$

ou, equivalentemente,

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left( b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij}x_j^{(k)} \right),$$

para  $i = 1, \dots, n$ .

# Métodos Numéricos

## Método de Gauss–Seidel

Vamos reescrever a fórmula recursiva na forma matricial. Para isso, passamos todos o termos do estágio  $k + 1$  para o lado esquerdo da igualdade. Assim, obtemos

$$\left( \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} \right) + a_{ii} x_i^{(k+1)} = b_i - \sum_{j=i+1}^n a_{ij} x_j^{(k)},$$

e então

$$\sum_{j=1}^i a_{ij} x_j^{(k+1)} = b_i - \sum_{j=i+1}^n a_{ij} x_j^{(k)}.$$

# Métodos Numéricos

## Método de Gauss-Seidel

Sejam  $L$  e  $U$  tais que  $A = L + U$ , com

$$L = \begin{pmatrix} a_{11} & 0 & \cdots & 0 \\ a_{21} & a_{22} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{pmatrix}, \quad \text{e} \quad U = \begin{pmatrix} 0 & a_{12} & \cdots & a_{1n} \\ 0 & 0 & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 0 \end{pmatrix}.$$

Com isso, obtemos a seguinte fórmula na forma matricial:

$$Lx^{(k+1)} = b - Ux^{(k)}, \quad (*)$$

que resulta em

$$x^{(k+1)} = L^{-1}(b - Ux^{(k)}).$$

# Métodos Numéricos

## Método de Gauss–Seidel

- O sistema (\*) pode ser resolvido usando substituição direta.
- Usamos como critério de parada no método de Gauss–Seidel o mesmo critério usado no método de Jacobi.

# Métodos Numéricos

## Método de Gauss–Seidel

### Exemplo

Use o método de Gauss–Seidel, com aproximação inicial  $x^{(0)} = (1, 1)^T$ , e  $\varepsilon = 5 \times 10^{-2}$  para o critério de parada, para encontrar a solução do sistema linear

$$\begin{cases} 5x_1 + 2x_2 = 1 \\ -x_1 + 4x_2 = 2 \end{cases}$$

R.:

$k$	$x^{(k)}$	$\frac{\ x^{(k)} - x^{(k-1)}\ _{\infty}}{\ x^{(k)}\ _{\infty}}$
0	$(1,00000; 1,00000)^T$	
1	$(-0,20000; 0,45000)^T$	2,66670
2	$(0,02000; 0,50500)^T$	0,43564
3	$(-0,00200; 0,49950)^T$	0,04404

### Exemplo

Considere o sistema linear

$$\begin{pmatrix} 4 & -2 & 1 \\ 1 & -3 & -1 \\ -1 & 0 & 2 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 2 \\ 4 \\ -1 \end{pmatrix}.$$

Dada a aproximação inicial  $x^{(0)} = (1, 1, 1)^T$ , use o método de Gauss-Seidel, para encontrar as aproximações sucessivas  $x^{(1)}$ ,  $x^{(2)}$  e  $x^{(3)}$ .

R.: Solução:  $(0,04; -1,16; -0,48)^T$ . Aproximações:

$k$	$x^{(k)}$
0	$(1,00000; 1,00000; 1,00000)^T$
1	$(0,75000; -1,41666; -0,12500)^T$
2	$(-0,17708; -1,35069; -0,58854)^T$
3	$(-0,02821; -1,14655; -0,51410)^T$



# Métodos Numéricos

## Convergência nos métodos de Jacobi e Gauss–Seidel

Os métodos de Jacobi e Gauss–Seidel podem ser expressos na forma matricial como

$$x^{(k+1)} = Cx^{(k)} + g, \quad \text{para } k \geq 0, \quad (*)$$

com  $x$  satisfazendo a igualdade  $x = Cx + g$  se, e somente se,  $Ax = b$ .

# Métodos Numéricos

## Convergência nos métodos de Jacobi e Gauss–Seidel

- Com respeito ao método de Jacobi, temos

$$x^{(k+1)} = D^{-1}(b - Mx^{(k)}) = -D^{-1}Mx^{(k)} + D^{-1}b,$$

e a fórmula (\*) é satisfeita para  $C = -D^{-1}M$  e  $g = D^{-1}b$ .

- Para esses valores de  $C$  e  $g$ , vemos que

$$Ax = (D + M)x = b$$

é equivalente a

$$x = D^{-1}(b - Mx) = Cx + g.$$

# Métodos Numéricos

## Convergência nos métodos de Jacobi e Gauss–Seidel

- Já no método de Gauss–Seidel, o desenvolvimento

$$x^{(k+1)} = L^{-1}(b - Ux^{(k)}) = -L^{-1}Ux^{(k)} + L^{-1}b$$

implica que (\*) é satisfeita para  $C = -L^{-1}U$  e  $g = L^{-1}b$ .

- Com esses valores de  $C$  e  $g$ , temos que

$$Ax = (L + U)x = b$$

é equivalente a

$$x = L^{-1}(b - Ux) = Cx + g.$$

# Métodos Numéricos

## Convergência nos métodos de Jacobi e Gauss-Seidel

Subtraindo as equações  $x^{(k+1)} = Cx^{(k)} + g$  e  $x = Cx + g$ , obtemos

$$x^{(k+1)} - x = C(x^{(k)} - x)$$

Usando a desigualdade triangular, chegamos a

$$\begin{aligned} |x_i^{(k+1)} - x_i| &= \left| \sum_{j=1}^n c_{ij}(x_j^{(k)} - x_j) \right| \leq \sum_{j=1}^n |c_{ij}| \cdot |x_j^{(k)} - x_j| \\ &\leq \left( \sum_{j=1}^n |c_{ij}| \right) \cdot \max_{1 \leq j \leq n} |x_j^{(k)} - x_j| \end{aligned}$$

Deste modo,

$$\max_{1 \leq i \leq n} |x_i^{(k+1)} - x_i| \leq \left[ \max_{1 \leq i \leq n} \left( \sum_{j=1}^n |c_{ij}| \right) \right] \cdot \max_{1 \leq j \leq n} |x_j^{(k)} - x_j|$$

# Métodos Numéricos

## Convergência nos métodos de Jacobi e Gauss–Seidel

Definindo

$$\|C\| = \max_{1 \leq i \leq n} \left( \sum_{j=1}^n |c_{ij}| \right)$$

podemos escrever

$$\|x^{(k+1)} - x\|_{\infty} \leq \|C\| \cdot \|x^{(k)} - x\|_{\infty}$$

Consequentemente,

$$\|x^{(k)} - x\|_{\infty} \leq \|C\|^k \cdot \|x^{(0)} - x\|_{\infty}.$$

Portanto, se  $\|C\| < 1$  então  $\|x^{(k)} - x\|_{\infty} \rightarrow 0$ , que implica  $x_i^{(k)} \rightarrow x_i$  para  $i = 1, \dots, n$ .

# Métodos Numéricos

## Convergência nos métodos de Jacobi e Gauss–Seidel

### Teorema (Critério de convergência)

Se  $\|C\| < 1$  então a sequência

$$x^{(k+1)} = Cx^{(k)} + g, \quad k \geq 0,$$

converge para  $x = Cx + g$ .

# Métodos Numéricos

## Convergência nos métodos de Jacobi e Gauss-Seidel

No método de Jacobi, a matriz  $C$  é dada por

$$C = -D^{-1}M = - \begin{pmatrix} 0 & \frac{a_{12}}{a_{11}} & \dots & \frac{a_{1n}}{a_{11}} \\ \frac{a_{21}}{a_{22}} & 0 & \dots & \frac{a_{2n}}{a_{22}} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{a_{n1}}{a_{nn}} & \frac{a_{n2}}{a_{nn}} & \dots & 0 \end{pmatrix}.$$

A desigualdade

$$\|C\| = \max_{1 \leq i \leq n} \left( \sum_{j \neq i} \left| \frac{a_{ij}}{a_{ii}} \right| \right) < 1$$

é satisfeita se e somente se

$$\sum_{j \neq i} |a_{ij}| < |a_{ii}|, \quad \text{para } i = 1, \dots, n. \quad (*)$$

Uma matriz  $A$  satisfazendo (\*) é chamada de diagonalmente estritamente dominante.

# Métodos Numéricos

## Convergência nos métodos de Jacobi e Gauss–Seidel

É possível verificar que, se  $A$  é diagonalmente estritamente dominante, então o método de Gauss–Seidel também converge.

### Teorema (Critério das linhas)

*Se a matriz  $A$  é diagonalmente estritamente dominante, i.e.,*

$$\sum_{j \neq i} |a_{ij}| < |a_{ii}|, \quad i = 1, \dots, n,$$

*então os métodos de Jacobi e Gauss–Seidel geram uma sequência que converge para a solução do sistema linear  $Ax = b$ , qualquer que seja a aproximação inicial  $x^{(0)}$ .*



### Exemplo

Verifique se o critério das linhas é válido para o sistema linear

$$\begin{cases} 8x_1 + 2x_2 - 2x_3 - 3x_4 = 1 \\ 2x_1 + 9x_2 + 3x_3 + 4x_4 = 5 \\ 3x_1 - 2x_2 + 7x_3 - 3x_4 = 3 \\ x_1 + 2x_2 + 3x_3 + 8x_4 = 2 \end{cases}$$

R.: Não é satisfeito.

## Identidade de Newton

Considere o polinômio

$$P(x) = a_0x^n + a_1x^{n-1} + \cdots + a_{n-1}x + a_n,$$

cujas raízes são  $x_1, x_2, \dots, x_n$ . Se denotarmos

$$s_k = \sum_{i=1}^n x_i^k, \quad 1 \leq k \leq n,$$

então vale a relação

$$\sum_{i=0}^{k-1} a_i s_{k-i} + k a_k = 0, \quad 1 \leq k \leq n.$$

### Exemplo

Sejam  $s_1 = 6$ ,  $s_2 = 14$  e  $s_3 = 36$  as somas das potências das raízes de um polinômio  $P(x)$ . Assumindo que o coeficiente líder é igual a 1 ( $a_0 = 1$ ), determine  $P(x)$ .

R.:  $P(x) = x^3 - 6x^2 + 11x - 6$ .

- O polinômio característico de uma matriz  $A$ , de dimensão  $n \times n$ , é definida como

$$P(\lambda) = \det(\lambda I - A).$$

- Adotaremos a seguinte notação para o polinômio característico:

$$P(\lambda) = \lambda^n - p_1\lambda^{n-1} - p_2\lambda^{n-2} - \dots - p_{n-1}\lambda - p_n.$$

- Sejam  $\lambda_1, \dots, \lambda_n$  os autovalores da matriz  $A$ . Isto é,  $\lambda_1, \dots, \lambda_n$  são as raízes do polinômio característico  $P(\lambda)$ .

- Pela identidade de Newton, se

$$s_k = \sum_{i=1}^n \lambda_i^k, \quad 1 \leq k \leq n,$$

então

$$kp_k = s_k - p_1 s_{k-1} - \cdots - p_{k-1} s_1, \quad 1 \leq k \leq n.$$

- Portanto, conhecendo  $s_1, \dots, s_n$ , pode-se determinar os coeficientes  $p_1, \dots, p_n$  de  $P(\lambda)$ .
- Os números  $s_1, \dots, s_n$  são encontrados como

$$s_k = \text{tr}(A^k), \quad 1 \leq k \leq n,$$

em que  $\text{tr}(\cdot)$  denota o traço da matriz.

- O procedimento acima para determinar os coeficientes  $p_1, \dots, p_n$  é chamado de Método de Leverrier.

### Exemplo

Encontre o polinômio característico e os autovalores da matriz

$$A = \begin{pmatrix} 1 & 1 & -1 \\ 0 & 0 & 1 \\ -1 & 1 & 0 \end{pmatrix},$$

usando o método de Leverrier.

$$\text{R.: } P(\lambda) = -\lambda^3 + 2\lambda^2 - 2\lambda + 2 = (\lambda - 1)(\lambda + \sqrt{2})(\lambda - \sqrt{2}).$$

- Defina uma sequência de matrizes  $B_1, \dots, B_n$  do seguinte modo:

$$B_1 = A, \quad q_1 = \text{tr}(B_1), \quad D_1 = B_1 - q_1 I,$$

e

$$B_k = AD_{k-1}, \quad q_k = \frac{1}{k} \text{tr}(B_k), \quad D_k = B_k - q_k I,$$

para  $2 \leq k \leq n$ .

- Os termos  $q_k$  obtidos acima constituem os coeficientes do polinômio característico, isto é,

$$q_k = p_k, \quad 1 \leq k \leq n.$$

- Tal procedimento é chamado de Método de Leverrier–Faddeev.

### Exemplo

Encontre o polinômio característico e os autovalores da matriz

$$A = \begin{pmatrix} 1 & -3 & 3 \\ 3 & -5 & 3 \\ 6 & -6 & 4 \end{pmatrix},$$

usando o método de Leverrier–Faddeev.

$$\text{R.: } P(\lambda) = \lambda^3 - 12\lambda - 16 = (\lambda - 4)(\lambda + 2)^2.$$



### Método das Potências

Seja  $A$  uma matriz real de dimensão  $n \times n$ , com autovalores  $\lambda_1, \dots, \lambda_n$  e respectivos autovetores  $v^{(1)}, \dots, v^{(n)}$ . Suponha que os autovetores são linearmente independentes, e que  $|\lambda_1| > |\lambda_2| \geq \dots \geq |\lambda_n|$ . Assuma que os autovetores são normalizados de forma que  $\|v^{(i)}\|_\infty = v_{q_i}^{(i)} = 1$  para algum índice  $q_i$ . Seja  $x^{(0)}$  um vetor cuja representação  $x^{(0)} = \sum_{i=1}^n c_i v^{(i)}$  satisfaz  $c_1 \neq 0$ . Considere as sequências de vetores  $x^{(k)}$  e  $y^{(k)}$  definidas por

$$y^{(k)} = Ax^{(k-1)} \quad \text{e} \quad x^{(k)} = \frac{y^{(k)}}{y_{p_k}^{(k)}}, \quad \text{para } k \geq 1,$$

em que  $p_k$  é o menor inteiro tal que  $|y_{p_k}^{(k)}| = \|y^{(k)}\|_\infty$ . Então  $x^{(k)}$  converge para  $v^{(1)}$ , e  $\lambda^{(k)} = y_{p_{k-1}}^{(k)}$  converge para  $\lambda_1$ .

- Em vista de

$$x^{(k)} = \frac{Ax^{(k-1)}}{y_{p_k}^{(k)}}, x^{(k-1)} = \frac{Ax^{(k-2)}}{y_{p_{k-1}}^{(k-1)}}, \dots, x^{(1)} = \frac{Ax^{(0)}}{y_{p_1}^{(1)}},$$

obtemos

$$x^{(k)} = \frac{A^k x^{(0)}}{y_{p_k}^{(k)} \cdots y_{p_1}^{(1)}}$$

- Como  $\|x^{(k)}\|_{\infty} = 1 = x_{p_k}^{(k)}$ , inferimos que  $y_{p_k}^{(k)} \cdots y_{p_1}^{(1)} = (A^k x^{(0)})_{p_k}$ .
- Com isso,

$$x^{(k)} = \frac{A^k x^{(0)}}{(A^k x^{(0)})_{p_k}}$$

- Em vista de  $A^k v^{(i)} = \lambda_i^k v^{(i)}$ , segue que

$$A^k x^{(0)} = \sum_{i=1}^n c_i \lambda_i^k v^{(i)} = \lambda_1^k \left( c_1 v^{(1)} + \sum_{i=2}^n c_i \left( \frac{\lambda_i}{\lambda_1} \right)^k v^{(i)} \right)$$

- Como  $|\lambda_i/\lambda_1| < 1$  para  $2 \leq i \leq n$ , obtemos que  $p_k = q_1$ , e assim  $v_{p_k}^{(1)} = v_{q_1}^{(1)} = 1$ , para todo  $k$  suficientemente grande.
- Logo,

$$x^{(k)} = \frac{c_1 v^{(1)} + \sum_{i=2}^n c_i \left( \frac{\lambda_i}{\lambda_1} \right)^k v^{(i)}}{c_1 v_{p_k}^{(1)} + \sum_{i=2}^n c_i \left( \frac{\lambda_i}{\lambda_1} \right)^k v_{p_k}^{(i)}} \rightarrow v^{(1)}$$

- Em vista das manipulações:

$$\begin{aligned}y_{p_{k-1}}^{(k)} &= (Ax^{(k-1)})_{p_{k-1}} \\&= \left( A \frac{A^{k-1}x^{(0)}}{(A^{k-1}x^{(0)})_{p_{k-1}}} \right)_{p_{k-1}} \\&= \frac{(A^k x^{(0)})_{p_{k-1}}}{(A^{k-1}x^{(0)})_{p_{k-1}}},\end{aligned}$$

podemos escrever

$$y_{p_{k-1}}^{(k)} = \lambda_1 \frac{c_1 v_{p_{k-1}}^{(1)} + \sum_{i=2}^n c_i \left(\frac{\lambda_i}{\lambda_1}\right)^k v_{p_{k-1}}^{(i)}}{c_1 v_{p_{k-1}}^{(1)} + \sum_{i=2}^n c_i \left(\frac{\lambda_i}{\lambda_1}\right)^{k-1} v_{p_{k-1}}^{(i)}} \rightarrow \lambda_1$$

- A seguir expomos uma ilustração do método das potências
- A matriz

$$A = \begin{pmatrix} -2 & -3 \\ 6 & 7 \end{pmatrix}$$

tem autovalores  $\lambda_1 = 4$  e  $\lambda_2 = 1$  com respectivos autovetores  $v^{(1)} = (-0,5; 1)^T$  e  $v^{(2)} = (1, -1)^T$ .

- Começando com  $x^{(0)} = (1, 1)^T$ , e multiplicando sucessivamente por  $A$ , obtemos

$$\begin{aligned} Ax^{(0)} &= \begin{pmatrix} -5 \\ 13 \end{pmatrix}, & A^2x^{(0)} &= \begin{pmatrix} -29 \\ 61 \end{pmatrix}, & A^3x^{(0)} &= \begin{pmatrix} -125 \\ 253 \end{pmatrix}, \\ A^4x^{(0)} &= \begin{pmatrix} -509 \\ 1021 \end{pmatrix}, & A^5x^{(0)} &= \begin{pmatrix} -2045 \\ 4093 \end{pmatrix}, & A^6x^{(0)} &= \begin{pmatrix} -8189 \\ 16381 \end{pmatrix} \end{aligned}$$

- Como consequência, aproximações para o autovetor dominante  $\lambda_1 = 4$  são

$$\lambda^{(1)} = \frac{13}{1} = 13,00000,$$

$$\lambda^{(2)} = \frac{61}{13} = 4,6923,$$

$$\lambda^{(3)} = \frac{253}{61} = 4,14754,$$

$$\lambda^{(4)} = \frac{1021}{253} = 4,03557,$$

$$\lambda^{(5)} = \frac{4093}{1021} = 4,00881,$$

$$\lambda^{(6)} = \frac{16381}{4093} = 4,00200$$

- Uma aproximação para o autovetor relativo ao autovalor dominante  $\lambda_1 = 4$  é

$$x^{(6)} = \frac{A^6 x^{(0)}}{(A^6 x^{(0)})_{p_6}} = \frac{1}{16381} \begin{pmatrix} -8189 \\ 16381 \end{pmatrix} = \begin{pmatrix} -0,49908 \\ 1 \end{pmatrix}$$

### Exemplo

Considere a matriz

$$A = \begin{pmatrix} -15 & 23 & -9 \\ -22 & 33 & -12 \\ -28 & 41 & -14 \end{pmatrix}.$$

Dado o vetor inicial  $x^{(0)} = (1, 0, 0)^T$ , aplicando o método das potências, encontre as aproximações  $\lambda^{(k)}$  e  $x^{(k)}$ , até a iteração  $k = 5$ , para o autovalor dominante  $\lambda_1$  e o respectivo autovetor  $v^{(1)}$  da matriz  $A$ .

R.:  $\lambda_1 = 4$ ,  $v^{(1)} = (1/3, 2/3, 1)^T$ . Aproximações:

$k$	$\lambda^{(k)}$	$x^{(k)}$
1	-15,00000	$(0,53571; 0,78571; 1,00000)^T$
2	3,21428	$(0,32222; 0,66666; 1,00000)^T$
3	4,31111	$(0,34793; 0,67525; 1,00000)^T$
4	3,94329	$(0,33267; 0,66666; 1,00000)^T$
5	4,01830	$(0,33425; 0,66720; 1,00000)^T$

# Métodos Numéricos

## Método QR

- O método QR é usado para encontrar os autovalores de uma matriz  $A$ .
- Um número  $\lambda \in \mathbb{R}$  é dito ser um autovalor da matriz  $A$  se existir um vetor  $v$  tal que

$$Av = \lambda v.$$

- O vetor  $v$  que satisfaz a equação acima é chamado de autovetor.
- Numa matriz triangular (superior ou inferior), seus autovalores correspondem aos elementos de sua diagonal.



- Na fatoração QR a matriz  $A$  é escrita como o produto

$$A = QR,$$

em que  $Q$  é uma matriz ortonormal, e  $R$  é uma matriz triangular superior.

- Uma matriz  $Q$  é chamada de ortonormal se

$$Q^T Q = Q Q^T = I.$$

- Se  $A$  é não singular, então a fatoração QR é única se é requerido que os elementos da diagonal de  $R$  são positivos.

- Para encontramos a fatoração QR de uma matriz  $A = (a_{ij})_{n \times n}$ , pode-se usar o processo de Gram–Schmidt.
- Para isso, expressamos a matriz  $A$  como

$$A = (a_1, \dots, a_n),$$

em que  $a_j = (a_{1j}, \dots, a_{nj})^T$  são os vetores coluna de  $A$ .

- No processo de Gram–Schmidt, um conjunto ortonormal de vetores coluna são gerados a partir dos vetores coluna de  $A$ .
- Dado um vetor coluna  $a$ , denotamos  $\|a\| = (a^T a)^{1/2}$ .

- Os vetores  $q_i$  são obtidos como

$$\begin{cases} a'_i = a_i - \sum_{k=1}^{i-1} (q_k^T a_i) q_k, \\ q_i = \frac{a'_i}{\|a'_i\|}. \end{cases}$$

- A matriz  $Q$  é então composta pelos vetores coluna  $q_i$ :

$$Q = (q_1, \dots, q_n).$$

- Já as entradas da matriz  $R = (r_{ij})$  são dadas como

$$r_{ij} = \begin{cases} q_i^T a_j, & i \leq j, \\ 0, & i > j. \end{cases}$$

- Os valores de  $r_{ij}$  são encontrados durante o cálculo dos vetores coluna  $q_i$ .

### Exemplo

Usando o processo de Gram–Schmidt, encontre a fatoração QR da matriz

$$A = \begin{pmatrix} 1 & 4 \\ 2 & 3 \end{pmatrix}.$$

$$\text{R.: } A = \begin{pmatrix} \frac{1}{\sqrt{5}} & \frac{2}{\sqrt{5}} \\ \frac{2}{\sqrt{5}} & -\frac{1}{\sqrt{5}} \end{pmatrix} \begin{pmatrix} \sqrt{5} & 2\sqrt{5} \\ 0 & \sqrt{5} \end{pmatrix}.$$

### Exemplo

Usando o processo de Gram–Schmidt, encontre a fatoração QR da matriz

$$A = \begin{pmatrix} 2 & 10 & 3 \\ 1 & -4 & -3 \\ 2 & 1 & -6 \end{pmatrix}.$$

$$\text{R.: } A = \begin{pmatrix} 2/3 & 2/3 & 1/3 \\ 1/3 & -2/3 & 2/3 \\ 2/3 & -1/3 & -2/3 \end{pmatrix} \begin{pmatrix} 3 & 6 & -3 \\ 0 & 9 & 6 \\ 0 & 0 & 3 \end{pmatrix}.$$

### Exemplo

Usando o processo de Gram–Schmidt, encontre a fatoração QR da matriz

$$A = \begin{pmatrix} -2 & 2 & 1 & 2 \\ 2 & 4 & 0 & 3 \\ -2 & 2 & 3 & 2 \\ 2 & 4 & 2 & 7 \end{pmatrix}.$$

$$\text{R.: } A = \begin{pmatrix} -1/2 & 1/2 & -1/2 & 1/2 \\ 1/2 & 1/2 & -1/2 & -1/2 \\ -1/2 & 1/2 & 1/2 & -1/2 \\ 1/2 & 1/2 & 1/2 & 1/2 \end{pmatrix} \begin{pmatrix} 4 & 2 & -1 & 3 \\ 0 & 6 & 3 & 7 \\ 0 & 0 & 2 & 2 \\ 0 & 0 & 0 & 2 \end{pmatrix}.$$

# Métodos Numéricos

## Método QR

- O método QR usa transformações de similaridade para transformar a matriz  $A$  na forma triangular.
- Uma transformação de similaridade é definida como  $A' = M^{-1}AM$ .
- As matrizes  $A$  e  $A'$  são ditas ser similares.
- Os autovalores de matrizes similares são idênticos, porém com autovetores diferentes.

- No método QR o produto  $A = QR$ , obtido na fatoração QR, é invertido resultando na matriz

$$A' = RQ.$$

- As matrizes  $A$  e  $A'$  são similares, e portanto têm os mesmos autovalores.
- Este resultado segue das igualdades abaixo:

$$Q^{-1}AQ = Q^{-1}QRQ = RQ = A'.$$



# Métodos Numéricos

## Método QR

- No método QR, dada a matriz  $A^{(k)}$  no  $k$ -ésimo estágio, encontramos sua decomposição QR como

$$A^{(k)} = Q^{(k)} R^{(k)},$$

e então calculamos

$$A^{(k+1)} = R^{(k)} Q^{(k)}.$$

- A inicialização é dada por  $A^{(0)} = A$ .
- Os elementos da diagonal de  $A^{(k)}$  convergem para os autovalores de  $A$ , a medida que  $A^{(k)}$  se aproxima da forma triangular superior.

### Teorema

*Seja  $A$  uma matriz não singular tendo autovalores*

$$\lambda_1, \dots, \lambda_n, \quad \text{com} \quad |\lambda_1| > \dots > |\lambda_n| > 0.$$

*Escolha a matriz  $X$  tal que*

$$X^{-1}AX = \Lambda := \text{diag}(\lambda_1, \dots, \lambda_n).$$

*Suponha que  $X^{-1}$  admite uma decomposição LU. Seja  $\{A^{(k)}\}$ , com  $A^{(0)} = A$ , a sequência gerada no método QR. Denote por  $a_{ij}^{(k)}$  a entrada de posição  $ij$  de  $A^{(k)}$ . Então*

$$a_{ij}^{(k)} \rightarrow 0, \quad \text{para } i > j,$$

*e*

$$a_{ii}^{(k)} \rightarrow \lambda_i, \quad \text{para } i = 1, \dots, n,$$

### Exemplo

Aplique o método QR, com 3 iterações, à matriz

$$A = \begin{pmatrix} 1 & 5 \\ 3 & 2 \end{pmatrix}.$$

R.:

### Exemplo

Aplique o método QR, com 3 iterações, à matriz

$$A = \begin{pmatrix} 25 & 32 & 40 \\ 32 & 1 & 8 \\ 40 & 8 & 37 \end{pmatrix}.$$

R.:  $\Lambda = \text{diag}(81, -27, 9)$ .

- No problema de interpolação, dado um conjunto de pares ordenados,  $(x_0, y_0), (x_1, y_1), \dots, (x_n, y_n)$ , com  $x_0, x_1, \dots, x_n$  distintos, que organizamos na tabela

$x$	$x_0$	$x_1$	$\cdots$	$x_n$
$y$	$y_0$	$y_1$	$\cdots$	$y_n$

procuramos uma função  $\varphi$  que interpola os pontos tabelados, ou seja,

$$\varphi(x_k) = y_k, \quad k = 0, 1, \dots, n.$$

- Na interpolação polinomial, a função  $\varphi$  é um polinômio de grau  $\leq n$ .
- Desta forma, desejamos encontrar um polinômio  $p_n$  de grau  $\leq n$  tal que

$$p_n(x_k) = y_k, \quad k = 0, 1, \dots, n.$$

- Denotando

$$p_n(x) = \alpha_0 + \alpha_1 x + \cdots + \alpha_n x^n,$$

queremos então encontrar  $\alpha_0, \alpha_1, \dots, \alpha_n$  tais que

$$\alpha_0 + \alpha_1 x_k + \cdots + \alpha_n x_k^n = y_k, \quad k = 0, \dots, n,$$

que corresponde a um sistema linear com  $n + 1$  equações e  $n + 1$  incógnitas.

- Na forma matricial, escrevemos

$$V\alpha = y,$$

em que

$$V = \begin{pmatrix} 1 & x_0 & x_0^2 & \cdots & x_0^n \\ 1 & x_1 & x_1^2 & \cdots & x_1^n \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_n & x_n^2 & \cdots & x_n^n \end{pmatrix}, \quad \alpha = \begin{pmatrix} \alpha_0 \\ \alpha_1 \\ \vdots \\ \alpha_n \end{pmatrix} \quad \text{e} \quad y = \begin{pmatrix} y_0 \\ y_1 \\ \vdots \\ y_n \end{pmatrix}.$$

- A matriz  $V$  é chamada de matriz de Vandermonde.
- O sistema  $V\alpha = y$  admite uma única solução, ou seja,  $\det(V) \neq 0$ , se os pontos  $x_0, x_1, \dots, x_n$  forem distintos.

### Teorema (Existência e Unicidade)

*Considere o conjunto  $\{(x_0, y_0), (x_1, y_1), \dots, (x_n, y_n)\}$ , com  $x_i \neq x_j$  para  $i \neq j$ . Então existe um único polinômio  $p_n$  de grau  $\leq n$  tal que  $p_n(x_k) = y_k$ , para  $k = 0, 1, \dots, n$ .*

### Exemplo

Resolva um sistema linear para encontrar o polinômio de grau  $\leq 2$  que interpola os pontos dados na tabela

$x$	$-1$	$2$	$3$
$y$	$-4$	$5$	$12$

R.:  $p_2(x) = -3 + 2x + x^2$ .



- A matriz de Vandermonde apresenta problemas de mal condicionamento.
- Portanto, o polinômio obtido da solução do sistema  $V\alpha = y$  pode conter erros de arredondamento.
- Veremos formas de encontrar o polinômio  $p_n$  que não utilizam a matriz de Vandermonde.

- Considere os polinômios

$$\begin{aligned} L_i(x) &= \frac{(x - x_0)(x - x_1) \cdots (x - x_{i-1})(x - x_{i+1}) \cdots (x - x_n)}{(x_i - x_0)(x_i - x_1) \cdots (x_i - x_{i-1})(x_i - x_{i+1}) \cdots (x_i - x_n)} \\ &= \prod_{k \neq i} \frac{(x - x_k)}{(x_i - x_k)}, \end{aligned}$$

para  $i = 0, 1, \dots, n$ .

- Note que  $L_i$  é um polinômio de grau  $n$  com raízes  $x_0, x_1, \dots, x_{i-1}, x_{i+1}, \dots, x_n$ .
- Além disso, esses polinômios satisfazem

$$L_i(x_k) = \begin{cases} 1, & i = k, \\ 0, & i \neq k. \end{cases}$$

- No método de Lagrange, o polinômio interpolador é dado como

$$\begin{aligned} p_n(x) &= y_0 L_0(x) + y_1 L_1(x) + \cdots + y_n L_n(x) \\ &= \sum_{k=0}^n y_k L_k(x). \end{aligned}$$

### Exemplo

Use o método de Lagrange para encontrar o polinômio de grau  $\leq 2$  que interpola os pontos dados na tabela

$x$	$-1$	$2$	$3$
$y$	$-4$	$5$	$12$

$$\text{R.: } p_2(x) = -3 + 2x + x^2.$$

### Exemplo

Usando o Método de Lagrange, encontre o valor do polinômio em  $x = 1$ , passando pelos pontos dados na tabela abaixo:

$x$	$-2$	$-1$	$3$	$4$
$y$	$12$	$6$	$42$	$126$

$$\text{R.: } p_3(1) = -12.$$

### Exemplo

Usando o Método de Lagrange, encontre o valor do polinômio em  $x = 1$ , passando pelos pontos dados na tabela abaixo:

$x$	-3	-2	-1	0	2
$y$	-41	-8	1	2	4

R.:  $p_4(1) = 3$ .

- O cálculo dos polinômios  $L_0, L_1, \dots, L_n$  é computacionalmente custoso.
- Como alternativa, temos o método de Newton em que o polinômio interpolador é dado por

$$p_n(x) = \alpha_0 + \alpha_1(x - x_0) + \alpha_2(x - x_0)(x - x_1) + \dots \\ \dots + \alpha_n(x - x_0)(x - x_1) \dots (x - x_{n-1}),$$

em que  $\alpha_0, \alpha_1, \dots, \alpha_n$  são obtidos da solução do sistema linear

$$\begin{pmatrix} 1 & & & & \\ 1 & (x_1 - x_0) & & & \\ 1 & (x_2 - x_0) & (x_2 - x_0)(x_2 - x_1) & & \\ \vdots & \vdots & \vdots & \ddots & \\ 1 & (x_n - x_0) & (x_n - x_0)(x_n - x_1) & \dots & (x_n - x_0) \dots (x_n - x_{n-1}) \end{pmatrix} \begin{pmatrix} \alpha_0 \\ \alpha_1 \\ \alpha_2 \\ \vdots \\ \alpha_n \end{pmatrix} = \begin{pmatrix} y_0 \\ y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}.$$

- Os coeficientes  $\alpha_0, \alpha_1, \dots, \alpha_n$  podem ser obtidos usando substituição direta.

Alternativamente, podemos calcular os coeficientes  $\alpha_0, \alpha_1, \dots, \alpha_n$  usando o operador diferenças divididas:

- Ordem 0:  $f[x_k] = f(x_k) = y_k$ ;
- Ordem 1:  $f[x_{k-1}, x_k] = \frac{f[x_k] - f[x_{k-1}]}{x_k - x_{k-1}}$ ;
- Ordem 2:  $f[x_{k-2}, x_{k-1}, x_k] = \frac{f[x_{k-1}, x_k] - f[x_{k-2}, x_{k-1}]}{x_k - x_{k-2}}$ ;
- Ordem  $l$ :  $f[x_{k-l}, \dots, x_k] = \frac{f[x_{k-l+1}, \dots, x_k] - f[x_{k-l}, \dots, x_{k-1}]}{x_k - x_{k-l}}$ .

# Métodos Numéricos

## Interpolação

Os cálculos podem ser organizados na seguinte tabela:

$x$	Ordem 0	Ordem 1	Ordem 2	Ordem 3	...	Ordem $n$
$x_0$	$y_0 = f[x_0]$					
		$f[x_0, x_1]$				
$x_1$	$y_1 = f[x_1]$		$f[x_0, x_1, x_2]$			
		$f[x_1, x_2]$		$f[x_0, x_1, x_2, x_3]$		
$x_2$	$y_2 = f[x_2]$		$f[x_1, x_2, x_3]$			
		$f[x_2, x_3]$		$f[x_1, x_2, x_3, x_4]$	$\ddots$	
$x_3$	$y_3 = f[x_3]$		$f[x_2, x_3, x_4]$			$f[x_0, x_1, \dots, x_n]$
		$f[x_3, x_4]$	$\vdots$	$\vdots$		
$x_4$	$y_4 = f[x_4]$	$\vdots$		$f[x_{n-3}, x_{n-2}, x_{n-1}, x_n]$	$\ddots$	
$\vdots$	$\vdots$	$f[x_{n-1}, x_n]$	$\ddots$			
$x_n$	$y_n = f[x_n]$	$\ddots$				

- Em termos do operador diferenças divididas, os coeficientes  $\alpha_0, \alpha_1, \dots, \alpha_n$  são dados por

$$\alpha_k = f[x_0, x_1, \dots, x_k], \quad k = 0, \dots, n.$$

- Portanto,

$$p_n(x) = f[x_0] + f[x_0, x_1](x - x_0) + f[x_0, x_1, x_2](x - x_0)(x - x_1) + \dots \\ \dots + f[x_0, x_1, \dots, x_n](x - x_0)(x - x_1) \dots (x - x_{n-1}).$$



- Na prática, o valor do polinômio  $p_n(x)$  para determinado  $x$  é obtido usando parênteses encaixados.
- O polinômio

$$p_n(x) = \alpha_0 + \alpha_1(x - x_0) + \alpha_2(x - x_0)(x - x_1) + \cdots \\ \cdots + \alpha_n(x - x_0)(x - x_1) \cdots (x - x_{n-1})$$

pode ser reescrito como

$$p_n(x) = \alpha_0 + (x - x_0)(\alpha_1 + (x - x_1)(\alpha_2 + \\ + (x - x_2)(\alpha_3 + \cdots + (x - x_{n-1})\alpha_n) \cdots)).$$

- Deste modo, o polinômio no método de Newton resulta em

$$p_n(x) = f[x_0] + (x - x_0)(f[x_0, x_1] + (x - x_1)(f[x_0, x_1, x_2] + \\ + (x - x_2)(f[x_0, x_1, x_2, x_3] + \cdots + (x - x_{n-1})f[x_0, x_1, \dots, x_n]) \cdots)).$$

# Métodos Numéricos

## Interpolação

### Exemplo

Use o método de Newton para encontrar o polinômio de grau  $\leq 2$  que interpola os pontos dados na tabela

$x$	$-1$	$2$	$3$
$y$	$-4$	$5$	$12$

$$\text{R.: } p_2(x) = -3 + 2x + x^2.$$

### Exemplo

Usando o Método de Newton, encontre o valor do polinômio em  $x = 3$ , passando pelos pontos dados na tabela abaixo:

$x$	$-3$	$-2$	$-1$	$0$
$y$	$-60$	$-9$	$2$	$-3$

$$\text{R.: } p_3(3) = 126.$$

### Exemplo

Usando o Método de Newton, encontre o valor do polinômio em  $x = 1$ , passando pelos pontos dados na tabela abaixo:

$x$	-3	-2	-1	0	2
$y$	-9	-6	1	2	3

R.:  $p_4(1) = -1,6$ .

- Vamos assumir que os pontos  $(x_0, y_0), \dots, (x_n, y_n)$  satisfazem

$$y_k = f(x_k), \quad k = 0, \dots, n,$$

em que  $f$  é a função a ser aproximada por um polinômio  $p_n$  de grau  $\leq n$ .

- O erro  $\mathcal{E}_n$  em  $x \in [x_0, x_n]$ , resultante da interpolação polinomial por  $p_n$ , é definido como

$$\mathcal{E}_n(x) = |f(x) - p_n(x)|.$$

### Teorema

Considere  $n + 1$  pontos  $x_0 < x_1 < \dots < x_n$ , com  $n \geq 0$ . Seja  $f$  uma função com derivada de ordem  $n + 1$  contínua no intervalo  $[x_0, x_n]$ . Se  $p_n$  é o polinômio que interpola  $f$  nos pontos  $x_0, \dots, x_n$ , então

$$f(x) - p_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} \prod_{k=0}^n (x - x_k), \quad x \in [x_0, x_n],$$

em que  $x_0 \leq \xi \leq x_n$ .

Consequentemente, o erro da interpolação polinomial satisfaz

$$\mathcal{E}_n(x) \leq \frac{M_{n+1}}{(n+1)!} \left| \prod_{k=0}^n (x - x_k) \right|, \quad x \in [x_0, x_n],$$

em que

$$M_{n+1} = \max_{x \in [x_0, x_n]} |f^{(n+1)}(x)|.$$

- Vamos mostrar que

$$f(x) - p_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} \pi(x), \quad x \in [x_0, x_n],$$

em que

$$\pi(x) = (x - x_0)(x - x_1) \cdots (x - x_n).$$

- Fixado  $x \neq x_k$  em  $[x_0, x_n]$ , defina a função

$$\mathcal{A}(t) = f(t) - p_n(t) - \frac{f(x) - p_n(x)}{\pi(x)} \pi(t), \quad t \in [x_0, x_n].$$

- Note que

$$\mathcal{A}(x) = 0 \quad \text{e} \quad \mathcal{A}(x_0) = 0, \mathcal{A}(x_1) = 0, \dots, \mathcal{A}(x_n) = 0,$$

já que  $f(x_k) = p_n(x_k)$ , para  $k = 0, \dots, n$ .

- Consequentemente,  $\mathcal{A}$  possui  $n + 2$  raízes em  $[x_0, x_n]$ .

- Pelo Teorema de Rolle,  $\mathcal{A}'$  possui  $n + 1$  raízes em  $(x_0, x_n)$ .
- Novamente, pelo Teorema de Rolle,  $\mathcal{A}''$  possui  $n$  raízes em  $(x_0, x_n)$ .
- Aplicando repetidas vezes o Teorema de Rolle, concluímos que  $\mathcal{A}^{(n+1)}$  possui uma raiz  $\xi \in (x_0, x_n)$ .
- Logo, temos

$$\mathcal{A}^{(n+1)}(\xi) = f^{(n+1)}(\xi) - p_n^{(n+1)}(\xi) - \frac{f(x) - p_n(x)}{\pi(x)}(n+1)! = 0.$$

- Como  $p_n^{(n+1)}(t) = 0$ , chegamos então a

$$f(x) - p_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} \pi(x), \quad x \in [x_0, x_n].$$

### Corolário

Considere  $n + 1$  pontos igualmente espaçados:

$$x_k = x_0 + kh, \quad k = 0, 1, \dots, n.$$

Seja  $f$  uma função com derivada de ordem  $n + 1$  contínua no intervalo  $[x_0, x_n]$ . Se  $p_n$  é o polinômio que interpola  $f$  nos pontos  $x_0, \dots, x_n$ , então o erro da interpolação polinomial satisfaz

$$\mathcal{E}_n(x) \leq \frac{M_{n+1} h^{n+1}}{4(n+1)}, \quad x \in [x_0, x_n],$$

em que

$$M_{n+1} = \max_{x \in [x_0, x_n]} |f^{(n+1)}(x)|.$$



# Métodos Numéricos

## Interpolação

- Fixado  $x \in [x_0, x_n]$ , seja  $0 \leq l \leq n$  tal que  $x \in (x_{l-1}, x_l)$ .
- Usando as desigualdades

$$(x - x_k) \leq h(l - k), \quad \text{para } 0 \leq k \leq l - 2,$$

$$(x - x_{l-1})(x_l - x) \leq \frac{h^2}{4},$$

$$(x_k - x) \leq h(k - l + 1), \quad \text{para } l + 1 \leq k \leq n,$$

e

$$(n - l + 1) \leq \binom{n}{l} \Rightarrow l! \cdot (n - l + 1)! \leq n!,$$

podem escrever

$$\begin{aligned} |\pi(x)| &= \prod_{k=0}^n |x - x_k| \\ &= \prod_{k=0}^{l-2} (x - x_k)(x - x_{l-1})(x_l - x) \prod_{k=l+1}^n (x_k - x) \end{aligned}$$

$$\begin{aligned} &\leq \left[ \prod_{k=0}^{l-2} h(l-k) \right] \frac{h^2}{4} \left[ \prod_{k=l+1}^n h(k-l+1) \right] \\ &= \frac{h^{n+1}}{4} \left[ \prod_{k=0}^{l-2} (l-k) \right] \left[ \prod_{k=l+1}^n (k-l+1) \right] \\ &= \frac{h^{n+1}}{4} \cdot l! \cdot (n-l+1)! \\ &\leq \frac{h^{n+1}}{4} n! \end{aligned}$$

- Com isso, chegamos a

$$\begin{aligned} \mathcal{E}_n(x) &= |f(x) - p_n(x)| = \left| \pi(x) \frac{f^{(n+1)}(\xi)}{(n+1)!} \right| \\ &\leq \frac{h^{n+1}}{4} n! \frac{M_{n+1}}{(n+1)!} = \frac{M_{n+1} h^{n+1}}{4(n+1)}. \end{aligned}$$

### Exemplo

Obtenha uma aproximação para  $\ln(2,3)$  e uma estimativa para o seu erro usando interpolação polinomial. Para isso, considere a tabela

$x$	1	2	3	4
$\ln(x)$	0	0,6931	1,0986	1,3863

R.:  $p_3(2,3) = 0,8373$ ,  $\mathcal{E}_3(2,3) \leq 0,375$ .

- Seja  $f: [a, b] \rightarrow \mathbb{R}$  uma função contínua e, geralmente, suave.
- Numa quadratura numérica de  $n + 1$  pontos, a integral é aproximada da seguinte forma:

$$I(f) = \int_a^b f(x) dx \simeq \sum_{k=0}^n w_k f(x_k),$$

em que

- $x_0, x_1, \dots, x_n \in [a, b]$  são os nós de integração, e
- $w_0, w_1, \dots, w_n$  são os pesos.
- A quadratura numérica é usada quando a função  $f$  é conhecida em apenas alguns pontos, ou quando não é possível calcular  $I(f)$  analiticamente.

- Nas fórmulas de Newton–Cotes, os pesos  $w_k$  são obtidos usando interpolação polinomial ou interpolação polinomial por partes em pontos  $x_0 < x_1 < \dots < x_n$  igualmente espaçados no intervalo  $[a, b]$ .
- Uma fórmula de Newton–Cotes é chamada de fechada se  $x_0 = a$  e  $x_n = b$ .
- Por outro lado, na fórmula aberta de Newton–Cotes, temos  $x_0, x_1, \dots, x_n \in (a, b)$ .

- Seja  $p_n$  o polinômio de grau  $n$  que interpola  $f$  nos pontos

$$x_k = a + \frac{b-a}{n}k, \quad k = 0, 1, \dots, n.$$

- Pela forma de Lagrange, temos

$$p_n(x) = \sum_{k=0}^n f(x_k)L_k(x),$$

em que

$$L_k(x) = \prod_{i \neq k} \frac{(x - x_i)}{(x_k - x_i)}.$$

- Deste modo,

$$\begin{aligned} I(f) &= \int_a^b f(x) dx \simeq \int_a^b p_n(x) dx \\ &= \int_a^b \left( \sum_{k=0}^n f(x_k) L_k(x) \right) dx \\ &= \sum_{k=0}^n \left( \int_a^b L_k(x) dx \right) f(x_k) \\ &= \sum_{k=0}^n w_k f(x_k), \end{aligned}$$

em que os pesos  $w_0, w_1, \dots, w_n$  são dados por

$$w_k = \int_a^b L_k(x) dx, \quad k = 0, 1, \dots, n.$$

- Na Regra dos Trapézios, consideramos  $n = 1$  com  $x_0 = a$  e  $x_1 = b$ .
- Sendo as bases de Lagrange dadas por

$$L_0(x) = \frac{x - x_1}{x_0 - x_1} = \frac{x_1 - x}{h}, \quad \text{e} \quad L_1(x) = \frac{x - x_0}{x_1 - x_0} = \frac{x - x_0}{h},$$

em que  $h = x_1 - x_0$ , temos

$$w_0 = \int_a^b L_0(x) dx = \int_{x_0}^{x_1} \frac{x_1 - x}{h} dx = \frac{h}{2},$$

$$w_1 = \int_a^b L_1(x) dx = \int_{x_0}^{x_1} \frac{x - x_0}{h} dx = \frac{h}{2}.$$

- Com isso, a Regra dos Trapézios resulta em

$$I(f) \simeq T_1(f) = \frac{h}{2}[f(x_0) + f(x_1)].$$



- Para melhorar a aproximação da integral pela Regra dos Trapézios, podemos fazer uma subdivisão do intervalo  $[a, b]$  com pontos

$$x_k = a + \frac{b-a}{n}k, \quad k = 0, 1, \dots, n,$$

e aplicar a Regra dos Trapézios em cada subintervalo  $[x_{k-1}, x_k]$ , para  $k = 1, \dots, n$ .

- Nesse caso, a função  $f$  é aproximada por um polinômio linear por partes  $\Pi_1$  que interpola  $f$  em  $x_0, x_1, \dots, x_n$ .

- Com isso, temos a aproximação

$$I(f) = \int_a^b f(x)dx \simeq \int_a^b \Pi_1(x)dx = \sum_{k=1}^n \int_{x_{k-1}}^{x_k} \Pi_1(x)dx = T_n(f).$$

- Considerando a aplicação da Regra dos Trapézios em cada subintervalo  $[x_{k-1}, x_k]$ , obtemos

$$I(f) \simeq T_n(f) = \sum_{k=1}^n \frac{h}{2} [f(x_{k-1}) + f(x_k)].$$

- A Regra dos Trapézios Composta é dada então como

$$I(f) \simeq T_n(f) = \frac{h}{2} [f(x_0) + 2f(x_1) + 2f(x_2) + \cdots + 2f(x_{n-1}) + f(x_n)].$$

- Seja

$$R_T = I(f) - T_1(f) = \int_{x_0}^{x_1} f(x) dx - \int_{x_0}^{x_1} p_1(x) dx.$$

- Considere a função contínua

$$\mathcal{A}(x) = f(x) - p_1(x) - \frac{R_T}{W} \pi(x),$$

em que  $\pi(x) = (x - x_0)(x - x_1)$ , e

$$W = \int_{x_0}^{x_1} \pi(x) dx = -\frac{h^3}{6} \neq 0.$$

- Como

$$\int_{x_0}^{x_1} \mathcal{A}(x) dx = 0,$$

podemos inferir que existe  $u \in (x_0, x_1)$  tal que  $\mathcal{A}(u) = 0$ .

- Portanto, a função  $\mathcal{A}(x)$  tem três zeros distintos em  $[x_0, x_1]$ .
- Aplicando repetidas vezes o Teorema de Rolle, concluimos que  $\mathcal{A}''(x)$  possui uma raiz  $\xi \in (x_0, x_1)$ .
- Logo, temos

$$0 = \mathcal{A}''(\xi) = f''(\xi) - \frac{R_T}{W} 2!,$$

de onde chegamos então a

$$R_T = \frac{f''(\xi)}{2!} W = \frac{f''(\xi)}{2!} \left(-\frac{h^3}{6}\right) = -\frac{h^3}{12} f''(\xi).$$

- No caso da Regra dos Trapézios Composta, considerando a expressão para o resto, obtemos

$$\begin{aligned} I(f) &= \sum_{k=1}^n \left( \frac{h}{2} [f(x_{k-1}) + f(x_k)] - \frac{h^3}{12} f''(\xi_k) \right) \\ &= T_n(f) - \underbrace{\frac{h^3}{12} \sum_{k=1}^n f''(\xi_k)}_{=R_T}. \end{aligned}$$

- Supondo que  $f''$  é contínua em  $[a, b]$ , uma aplicação Teorema do Valor Intermediário fornece a existência de  $\xi \in (a, b)$  tal que

$$R_T = -\frac{h^3}{12} \sum_{k=1}^n f''(\xi_k) = -\frac{h^3}{12} n f''(\xi) = -n \frac{h^3}{12} f''(\xi).$$

- Portanto, o erro na Regra dos Trapézios Composta, supondo  $f''$  contínua em  $[a, b]$ , satisfaz

$$|R_T| = |I(f) - T_n(f)| \leq \frac{(b-a)^3}{12n^2} M_2,$$

em que

$$M_2 = \max_{a \leq \xi \leq b} |f''(\xi)|.$$

### Exemplo

Usando a Regra dos Trapézios Composta, calcule o valor da integral

$$\int_0^1 e^x dx,$$

com erro  $|R_T| < 10^{-2}$ .

R.:  $n = 5$ ,  $T_5(f) = 1,724005$ .

### Exemplo

Usando a Regra dos Trapézios Composta, calcule o valor da integral

$$\int_0^1 \ln(\cos x) dx,$$

com erro  $|R_T| < 10^{-2}$ .

R.:  $n = 6$ ,  $T_6(f) = -0,191132$ .



### Exemplo

Usando a Regra dos Trapézios Composta, calcule o valor da integral

$$\int_0^1 (x - 2)e^x dx,$$

com erro  $|R_T| < 7 \times 10^{-3}$ .

R.:  $n = 6$ ,  $T_6(f) = -2,434253$ .

- A Regra 1/3 de Simpson é obtida considerando  $n = 2$ , com

$$x_0 = a, \quad x_1 = (a + b)/2 \quad \text{e} \quad x_2 = b.$$

- Neste caso, as integrais dos polinômios de Lagrange resultam em

$$w_0 = \int_a^b L_0(x) dx = \int_{x_0}^{x_2} \frac{(x - x_1)(x - x_2)}{(x_0 - x_1)(x_0 - x_2)} dx = \frac{h}{3},$$

$$w_1 = \int_a^b L_1(x) dx = \int_{x_0}^{x_2} \frac{(x - x_0)(x - x_2)}{(x_1 - x_0)(x_1 - x_2)} dx = \frac{4h}{3},$$

$$w_2 = \int_a^b L_2(x) dx = \int_{x_0}^{x_2} \frac{(x - x_0)(x - x_1)}{(x_2 - x_0)(x_2 - x_1)} dx = \frac{h}{3},$$

que podem ser calculadas considerando  $z = x - x_0$ .

- Portanto, a Regra 1/3 de Simpson é dada por

$$I(f) \simeq S_2(f) = \frac{h}{3} [f(x_0) + 4f(x_1) + f(x_2)].$$

- Para melhorar a aproximação da integral pela Regra 1/3 de Simpson, podemos fazer uma subdivisão do intervalo  $[a, b]$  com pontos

$$x_k = a + \frac{b-a}{n}k, \quad k = 0, 1, \dots, n,$$

e aplicar a Regra 1/3 de Simpson em cada subintervalo  $[x_{2k-2}, x_{2k}]$ , para  $k = 1, \dots, n/2$ .

- Nesse caso, a função  $f$  é aproximada por um polinômio quadrático por partes  $\Pi_2$  que interpola  $f$  em  $x_0, x_1, \dots, x_n$ .

- Com isso, temos a aproximação

$$I(f) = \int_a^b f(x)dx \simeq \int_a^b \Pi_2(x)dx = \sum_{k=1}^{n/2} \int_{x_{2k-2}}^{x_{2k}} \Pi_2(x)dx = S_n(f).$$

- Considerando a aplicação da Regra 1/3 de Simpson em cada subintervalo  $[x_{2k-2}, x_{2k}]$ , obtemos

$$I(f) \simeq S_n(f) = \sum_{k=1}^{n/2} \frac{h}{3} [f(x_{2k-2}) + 4f(x_{2k-1}) + f(x_{2k})].$$

- Deste modo, a Regra 1/3 de Simpson Composta é dada como

$$S_n(f) = \frac{h}{3} [f(x_0) + 4f(x_1) + 2f(x_2) + 4f(x_3) + \cdots + 2f(x_{n-2}) + 4f(x_{n-1}) + f(x_n)]$$

- Assim como na Regra dos Trapézios, pode-se mostrar que o resto na Regra 1/3 de Simpson, supondo  $f^{(4)}$  contínua em  $[a, b]$ , satisfaz

$$R_S = I(f) - S_2(f) = -\frac{h^5}{90}f^{(4)}(\xi), \quad \xi \in (a, b).$$

- Para isso, denotamos

$$\pi(x) = (x - x_0)(x - x_1)(x - x_2),$$

$$\tilde{\pi}(x) = (x - x_0)(x - x_1)^2(x - x_2),$$

e assim temos

$$W = \int_{x_0}^{x_2} \pi(x) dx = 0,$$

$$\widetilde{W} = \int_{x_0}^{x_2} \tilde{\pi}(x) dx = -\frac{4}{15}h^5 \neq 0.$$

- Considere a função contínua

$$\mathcal{A}(x) = f(x) - p_2(x) - k\pi(x) - \frac{R_S}{W}\tilde{\pi}(x),$$

em que a constante  $k \in \mathbb{R}$  é escolhida de modo que

$$\int_{x_0}^{x_1} \mathcal{A}(x) dx = 0,$$

visto que  $\int_{x_0}^{x_1} \pi(x) dx \neq 0$ .

- Como  $\int_{x_0}^{x_2} \mathcal{A}(x) dx = 0$ , concluímos que

$$\int_{x_1}^{x_2} \mathcal{A}(x) dx = 0.$$

- Com isso, existem  $u \in (x_0, x_1)$  e  $v \in (x_1, x_2)$  tais que  $\mathcal{A}(u) = \mathcal{A}(v) = 0$ .

- Portanto, a função  $\mathcal{A}(x)$  tem cinco zeros distintos em  $[x_0, x_2]$ .
- Aplicando repetidas vezes o Teorema de Rolle, concluímos que  $\mathcal{A}^{(4)}(x)$  possui uma raiz  $\xi \in (x_0, x_2)$ .
- Logo, temos

$$0 = \mathcal{A}^{(4)}(\xi) = f^{(4)}(\xi) - \frac{R_S}{\widetilde{W}} 4!,$$

de onde chegamos então a

$$R_S = \frac{f^{(4)}(\xi)}{4!} \widetilde{W} = \frac{f^{(4)}(\xi)}{4!} \left( -\frac{4}{15} h^5 \right) = -\frac{h^5}{90} f^{(4)}(\xi).$$

- No caso da Regra 1/3 de Simpson Composta, considerando a expressão para o resto, obtemos

$$\begin{aligned} I(f) &= \sum_{k=1}^{n/2} \left( \frac{h}{3} [f(x_{2k-2}) + 4f(x_{2k-1}) + f(x_{2k})] - \frac{h^5}{90} f^{(4)}(\xi_k) \right) \\ &= S_n(f) - \underbrace{\frac{h^5}{90} \sum_{k=1}^{n/2} f^{(4)}(\xi_k)}_{=R_S}. \end{aligned}$$

- Supondo que  $f^{(4)}$  é contínua em  $[a, b]$ , o Teorema do Valor Intermediário fornece a existência de  $\xi \in (a, b)$  tal que

$$R_S = -\frac{h^5}{90} \sum_{k=1}^{n/2} f^{(4)}(\xi_k) = -\frac{h^5}{90} \left( \frac{n}{2} f^{(4)}(\xi) \right) = -n \frac{h^5}{180} f^{(4)}(\xi).$$



- Portanto, o resto na Regra 1/3 de Simpson Composta, supondo  $f^{(4)}$  contínua em  $[a, b]$ , satisfaz

$$|R_S| = |I(f) - S_n(f)| \leq \frac{(b-a)^5}{180n^4} M_4,$$

em que

$$M_4 = \max_{a \leq \xi \leq b} |f^{(4)}(\xi)|.$$

### Exemplo

Calcule o valor da integral

$$\int_0^1 e^x dx,$$

aplicando a Regra 1/3 de Simpson Composta, com erro  $|R_S| < 10^{-4}$ .

### Exemplo

Calcule o valor da integral

$$\int_1^3 \ln(x+1)dx,$$

aplicando a Regra 1/3 de Simpson Composta, com erro  $|R_S| < 10^{-4}$ .

R.:  $n = 6$ ,  $S_6(f) = 2,158868$ .

### Exemplo

Calcule o valor da integral

$$\int_0^1 (x \sen x + 4 \cos x) dx,$$

aplicando a Regra 1/3 de Simpson Composta, com erro  $|R_S| < 10^{-5}$ .

R.:  $n = 6$ ,  $S_6(f) = 3,6670538$ .

- Na quadratura Gaussiana dada por

$$I(f) = \int_a^b f(x)dx \simeq G_n(f) = \sum_{k=0}^n w_k f(x_k),$$

os nós de integração  $x_0, x_1, \dots, x_n$  não são pontos igualmente espaçados em  $[a, b]$ .

- Tanto os nós de integração como os pesos são escolhidos de modo que  $R_{n+1} = 0$  se  $f$  for um polinômio de grau  $\leq 2n + 1$ .

- Para  $n = 1$  e  $[a, b] = [-1, 1]$ , devemos ter

$$G_1(f) = \int_{-1}^1 f(t)dt = w_0 f(t_0) + w_1 f(t_1),$$

sempre que  $f$  for um polinômio de grau  $\leq 3$ .

- Deste modo,

$$\int_{-1}^1 1dx = w_0 f(t_0) + w_1 f(t_1) \Rightarrow w_0 + w_1 = 2,$$

$$\int_{-1}^1 xdx = w_0 f(t_0) + w_1 f(t_1) \Rightarrow w_0 t_0 + w_1 t_1 = 0,$$

$$\int_{-1}^1 x^2 dx = w_0 f(t_0) + w_1 f(t_1) \Rightarrow w_0 t_0^2 + w_1 t_1^2 = \frac{2}{3},$$

$$\int_{-1}^1 x^3 dx = w_0 f(t_0) + w_1 f(t_1) \Rightarrow w_0 t_0^3 + w_1 t_1^3 = 0.$$

- Como consequência, obtemos o seguinte sistema não linear:

$$\begin{cases} w_0 + w_1 = 2 \\ w_0 t_0 + w_1 t_1 = 0 \\ w_0 t_0^2 + w_1 t_1^2 = \frac{2}{3} \\ w_0 t_0^3 + w_1 t_1^3 = 0 \end{cases}$$

cuja solução é

$$t_0 = -\frac{1}{\sqrt{3}}, \quad t_1 = +\frac{1}{\sqrt{3}}, \quad \text{e} \quad w_0 = w_1 = 1.$$

- No caso de um intervalo  $[a, b]$  qualquer, a mudança de variável

$$x = \frac{1}{2}(a + b + t(b - a))$$

resulta na quadratura Gaussiana dada por

$$G_1(f) = \frac{b-a}{2} \left[ f\left(\frac{a+b}{2} - \frac{b-a}{2\sqrt{3}}\right) + f\left(\frac{a+b}{2} + \frac{b-a}{2\sqrt{3}}\right) \right].$$

### Exemplo

Estime  $I(f) = \int_0^1 e^x dx$  usando a quadratura Gaussiana  $G_1(f)$  e determine o erro resultante.

### Exemplo

Estime  $I(f) = \int_0^1 (x-2)e^x dx$  usando a quadratura Gaussiana  $G_1(f)$  e determine o erro resultante.

### Exemplo

Estime  $I(f) = \int_1^3 \ln(x+1) dx$  usando a quadratura Gaussiana  $G_1(f)$  e determine o erro resultante.



- Um problema de valor inicial (PVI) é uma equação diferencial dada na forma

$$\begin{cases} \frac{dy}{dx} = f(x, y), \\ y(x_0) = y_0, \end{cases}$$

em que  $f$  é uma função dada, com condição inicial  $y(x_0) = y_0$ , para  $x_0$  e  $y_0$  fixados.

- Assumiremos que o PVI possui uma única solução  $y(x)$ .

# Métodos Numéricos

## Solução numérica de PVI

- Assuma que pontos  $x_0, x_1, \dots$  são igualmente espaçados, ou seja,

$$x_{k+1} = x_k + h, \quad k = 0, 1, \dots$$

para dado passo  $h$ .

- O método de Euler é dado pela fórmula

$$y_{k+1} = y_k + hf(x_k, y_k), \quad k = 0, 1, \dots$$

- Se  $y''(x)$  for contínua, então, pela série de Taylor centrada em  $x_k$  temos

$$y(x_k + h) = y(x_k) + y'(x_k)h + \frac{1}{2}y''(\xi)h^2, \quad \xi \in (x_k, x_k + h),$$

que reescrevemos como

$$y(x_{k+1}) = y(x_k) + hf(x_k, y(x_k)) + \frac{1}{2}y''(\xi)h^2,$$

onde usamos  $x_{k+1} = x_k + h$  e  $y'(x_k) = f(x_k, y(x_k))$ .

- Assumindo  $y_k = y(x_k)$ , o erro do método de Euler em  $x_{k+1}$  é então

$$e(x_{k+1}) = |y(x_{k+1}) - y_{k+1}| = \frac{1}{2}|y''(\xi)|h^2 \leq \frac{h^2}{2}M_2,$$

em que

$$M_2 = \max_{x_k \leq \xi \leq x_{k+1}} |y''(\xi)|.$$

### Definição

Um método numérico para um PVI é dito ser de ordem  $p$  se existe uma constante  $C$  tal que o erro  $e(x_{k+1}) = |y(x_{k+1}) - y_{k+1}|$ , onde se assume  $y_k = y(x_k)$ , satisfaz

$$e(x_{k+1}) < Ch^{p+1},$$

em que  $C$  é uma constante.

### Exemplo

Usando o Método de Euler, estabeleça aproximações para o PVI

$$\begin{cases} \frac{dy}{dx} = \frac{1}{x+1}, \\ y(0) = 1, \end{cases}$$

no intervalo  $[0; 1,2]$ , com  $h = 0,4$ .

### Exemplo

Usando o Método de Euler, estabeleça aproximações para o PVI

$$\begin{cases} \frac{dy}{dx} = \frac{1}{1 + xy}, \\ y(0) = 0, \end{cases}$$

no intervalo  $[0, 1]$ , com  $h = 0,25$ .

### Exemplo

Usando o Método de Euler, estabeleça aproximações para o PVI

$$\begin{cases} \frac{dy}{dx} = x^2 - 2y, \\ y(0) = 1, \end{cases}$$

no intervalo  $[0, 1]$ , com  $h = 0,2$ .

# Métodos Numéricos

## Solução numérica de PVI

- Os chamados métodos de Runge–Kutta de  $s$  estágios apresentam a forma

$$y_{k+1} = y_k + h\phi(x_k, y_k), \quad k = 0, 1, \dots,$$

em que  $\phi = b_1 k_1 + \dots + b_s k_s$ , e

$$k_1 = f(x, y),$$

$$k_2 = f(x + c_2 h, y + h a_{21} k_1),$$

$$k_3 = f(x + c_3 h, y + h(a_{31} k_1 + a_{32} k_2)),$$

$$\vdots$$

$$k_s = f(x + c_s h, y + h(a_{s1} k_1 + \dots + a_{s,s-1} k_{s-1})),$$

com as constantes  $c_i$ ,  $a_{ij}$ ,  $b_j$  sendo definidas para cada método particular.

- O método de Euler, em que  $\phi = f$ , é um método de Runge–Kutta de estágio  $s = 1$  e ordem  $p = 1$ .



# Métodos Numéricos

## Solução numérica de PVI

- As constantes do método de Runge–Kutta podem ser organizados como na tabela

0					
$c_2$	$a_{21}$				
$c_3$	$a_{31}$	$a_{32}$			
$\vdots$	$\vdots$	$\vdots$	$\ddots$		
$c_s$	$a_{s1}$	$a_{s2}$	$\cdots$	$a_{s,s-1}$	
	$b_1$	$b_2$	$\cdots$	$b_{s-1}$	$b_s$

# Métodos Numéricos

## Solução numérica de PVI

- Pode-se mostrar que o método de Runge–Kutta de 2 estágios tem ordem  $p = 2$  se

$$b_1 + b_2 = 1, \quad b_2 c_2 = \frac{1}{2}, \quad b_2 a_{21} = \frac{1}{2}.$$

- Dois métodos que satisfazem a relação acima são o método de Euler modificado, cujas constantes são dadas na tabela

0		
1/2	1/2	
		0 1

e o método de Euler melhorado, com constantes dadas abaixo

0		
1	1	
		1/2 1/2

- O método de Euler modificado apresenta a forma

$$y_{k+1} = y_k + hf\left(x_k + \frac{h}{2}, y_k + \frac{h}{2}f(x_k, y_k)\right).$$

- Já o método de Euler melhorado tem a forma

$$y_{k+1} = y_k + \frac{h}{2}[f(x_k, y_k) + f(x_k + h, y_k + hf(x_k, y_k))].$$

### Exemplo

Compare a solução do PVI

$$\begin{cases} \frac{dy}{dx} = -2xy^2, \\ y(0) = 0,5, \end{cases}$$

no intervalo  $[0, 1]$ , com 10 subintervalos, usando os métodos de Euler, Euler modificado e Euler melhorado, sabendo que a solução é

$$y(x) = \frac{1}{x^2 + 2}.$$

# Métodos Numéricos

## Solução numérica de PVI

$x_i$	$ y_i^E - y(x_i) $	$ y_i^{\text{Emod}} - y(x_i) $	$ y_i^{\text{Emel}} - y(x_i) $
0,0	0	0	0
0,1	$2,49 \times 10^{-3}$	$1,24 \times 10^{-5}$	$1,24 \times 10^{-5}$
0,2	$4,80 \times 10^{-3}$	$4,76 \times 10^{-5}$	$2,32 \times 10^{-5}$
0,3	$6,73 \times 10^{-3}$	$9,83 \times 10^{-5}$	$2,97 \times 10^{-5}$
0,4	$8,11 \times 10^{-3}$	$1,55 \times 10^{-4}$	$2,89 \times 10^{-5}$
0,5	$8,88 \times 10^{-3}$	$2,06 \times 10^{-4}$	$1,91 \times 10^{-5}$
0,6	$9,04 \times 10^{-3}$	$2,45 \times 10^{-4}$	$2,60 \times 10^{-8}$
0,7	$8,69 \times 10^{-3}$	$2,67 \times 10^{-4}$	$2,70 \times 10^{-5}$
0,8	$7,94 \times 10^{-3}$	$2,71 \times 10^{-4}$	$5,96 \times 10^{-5}$
0,9	$6,93 \times 10^{-3}$	$2,59 \times 10^{-4}$	$9,48 \times 10^{-5}$
1,0	$5,77 \times 10^{-3}$	$2,35 \times 10^{-4}$	$1,30 \times 10^{-4}$

# Métodos Numéricos

## Solução numérica de PVI

- Um método bastante comum de ordem 4 é o método de Runge–Kutta com coeficientes dados na tabela

0				
1/2	1/2			
1/2	0	1/2		
1	0	0	1	
<hr/>				
	1/6	1/3	1/3	1/6

- Para esses coeficientes o método de Runge–Kutta apresenta a forma

$$y_{k+1} = y_k + \frac{h}{6}(k_1 + 2k_2 + 2k_3 + k_4),$$

em que

$$\begin{aligned}k_1 &= f(x_k, y_k), & k_3 &= f\left(x_k + \frac{h}{2}, y_k + \frac{h}{2}k_2\right), \\k_2 &= f\left(x_k + \frac{h}{2}, y_k + \frac{h}{2}k_1\right), & k_4 &= f(x_k + h, y_k + hk_3).\end{aligned}$$

### Exemplo

Considere o PVI

$$\begin{cases} \frac{dy}{dx} = y, \\ y(0) = 1. \end{cases}$$

Use o método de Euler melhorado e o método de Runge–Kutta de ordem 4 para estimar  $y(0,04)$  com  $h = 0,04$ . Compare com a solução  $y(0,04) = e^{0,04}$ .

