

Figura 02

AP-2

- 1-Descreva uma rede neural Perceptron
- 2-Descreva uma rede neural MLP
- 3-Descreva uma rede neural RBF

5) O neurônio Biológico que é influenciado por a criação do Red MP tem seus distributos, axônios, e assim o limiar na estrutura da red percepção não é diferente visto que a junção do MP com o ruído de aprendizagem, assim como podemos obter a estrutura desse neurônio conforme a Figura 03, de modo que temos seus dados de entrada o vetor $\vec{x}$ que passa sobre os neurônios e sobre os pesos onde o cálculo dos pesos é dado pela equação $w(t+1) = w(t) + n.e.x(t)$, dependendo do erro que é calculado com $e = d - y$, onde d é o valor desejado e y é o valor obtido temos uma função de ativação de Heaviside, outro ponto para se destacar é que a função




Figura 03.

Para apenas os dados que são linearmente separáveis como as portas AND, OR, NOT, usando isso, se destacar também sobre o ângulo formado por $\alpha(w, x)$ em que está diretamente relacionado ao erro. Se tivermos um $\alpha > 90^\circ$, obtemos $e = -1$ e que o valor $w(t+1) = w(t) - n.e.x(t)$, logo assumimos que o valor $d = 0$ e $y = 1$, assim temos que $w(t+1) = w(t) - n.e.x(t)$. Se tivermos um $\alpha < 90^\circ$, obtemos $e = 1$ e $y = 0$, assim temos que $w(t+1) = w(t) + n.e.x(t)$. Isso implica em dizer que o





Figura 02

AP-0

- 1- Descreva uma red neural Percepção
- 2- Descreva uma red neural MLP
- 3- Descreva uma red neural RBF



2. Descreva uma rede neural MLP

Para descrevermos uma rede neural de uma maneira que enquanto rede neural de percepção temos uma função de ativação no formato de sigmoide, e nessa rede utilizamos uma função de modo sigmoide onde em sua estrutura temos que $\vec{x}$ é o vetor de entrada onde temos o comando de entrada que nos leva a uma camada oculta que tem duas partes e nesse comando o resultado é levado para uma camada de saída, as camadas ocultas de comandos intermediárias fazem o processo de separação de modo que transformamos um problema não linearmente separável em um problema linearmente separável como a porta XOR, conforme a ilustração da Figura 03, em




Figura 03

que os pontos $(0,0)$ e $(1,1)$ se transformam em um único ponto e com isso instantaneamente temos que a porta XOR não linearmente separável, isso tudo graças a divisão da porta camada oculta. Um bom ponto para se destacar é sobre a quantidade de camadas ocultas, quanto maior for a

quantidade de camadas ocultas, menor vai ser a propagação do erro. Outro fator é a utilização de uma quantidade maior onde pegamos o quadro de todos os erros por e fazemos o seu médio, não garantindo que o erro seja sempre um valor positivo. A expressão dada para calcular o ~~erro~~ ^{potencial} $w(t+1) = w(t) + \eta \cdot e(t) \cdot O'(t) \cdot X(t) \cdot Z(t)$. Para o processo de separação do MLP obtemos que o erro seja próximo de zero e a quantidade de épocas seja atingida.




Figura 04

A definição de forward se dá na utilização dos dados em busca de uma saída onde cada um deles pode utilizar os pesos com base no Backward, por meio dos erros de cada nó navegamos no neurônio atualizando os pesos que melhor se adapta na situação.

A saída dos dados para a rede neural MLP é dada como se fosse analógico e não mais binária como a de percepção.

4/2/19

3ª Descrevo uma Rede neural RBF.

A rede neural RBF difere da rede neural MLP, basicamente, em apenas uma camada de entrada, uma camada intermediária e uma camada de saída de modo que entre as camadas de entrada e a camada intermediária não tenha atuação dos pesos, já na camada oculta e a camada de saída é utilizado um peso por neurônio no novo processamento, de forma simples, a estrutura da RBF é dividida em 3 etapas. O primeiro estágio faz o processamento dos dados onde se jogamos os dados de entrada X , colocamos centros de clusters e classificamos os dados conforme a expressão $U = \|X - c\|$ onde X é o dado recebido, c é o centro de que um primeiro ponto é aleatório de pois com a classificação dos dados utilizamos o K-means para calculamos a distância entre os dados e calculamos seu novo centro de e posso reorganizar e classificamos novamente até que fique constante, todos os dados pertencem a alguma classificação. Para o segundo estágio com os dados recebidos utilizamos as fórmulas ~~para reorganizar~~ e reparamos os dados, uma outra observação é sobre o primeiro estágio onde após encontrar o centro de criamos uma forma circular que ~~abrange~~ contêm todos os dados dentro de suas classificações.

